

Отчет по лабораторной работе №5

Полиномиальная регрессия и методы оптимизации

Выполнили:

Новиков Алексей Георгиевич, группа М3233

Душкин Александр Алексеевич, группа М3233

Санкт-Петербург

2026

Содержание

1	Постановка задачи	2
2	Данные и модели	2
3	Методы оптимизации	3
3.1	Аналитическое решение	3
3.2	SGD и mini-batch GD	3
3.3	Гаусс–Ньютон и Левенберг–Марквардт	4
4	Результаты	4
4.1	Сравнение методов	4
4.2	Влияние степени полинома	5
4.3	Регуляризация	6
4.4	Сравнение Gauss–Newton и Levenberg–Marquardt	6
4.5	Исследование batch size	7
5	Графики	8
5.1	Fit-графики базовых моделей	8
5.2	Динамика loss	12
6	Полная таблица экспериментов	20
7	Общий вывод	25

1 Постановка задачи

Цель работы — рассмотреть задачу одномерной регрессии как задачу оптимизации и сравнить несколько способов минимизации функции потерь. В работе использовались полиномиальные модели степеней от 1 до 5, два искусственных набора данных, варианты без регуляризации, с L1, L2 и Elastic Net, а также несколько оптимизаторов: аналитическое решение для линейной модели, SGD, mini-batch GD, Гаусс–Ньютон и Левенберг–Марквардт.

Для модели степени d использовалась матрица признаков

$$X = [1, z, z^2, \dots, z^d],$$

где z — нормированное значение исходного признака. Базовая функция потерь:

$$L(w) = \frac{1}{m} \|Xw - y\|^2.$$

При регуляризации добавлялись члены

$$\lambda_1 \sum_{i=1}^d \sqrt{w_i^2 + \delta^2} \quad \text{и} \quad \lambda_2 \sum_{i=1}^d w_i^2.$$

Свободный коэффициент w_0 в этих экспериментах не регуляризовался: штраф применялся только к коэффициентам при степенях нормированного признака. Для L1 использовалась сглаженная аппроксимация модуля с малым δ , чтобы сохранять дифференцируемость функции потерь для градиентных и гаусс–ньютоновских методов.

Промежуточный вывод. Регрессия удобна тем, что одна и та же задача допускает разные методы. Для линейного случая есть аналитическая формула, для стохастических методов важны батчи и шаг, а методы Гаусса–Ньютона используют структуру суммы квадратов через якобиан остатков.

2 Данные и модели

Для каждого набора данных было сгенерировано $m = 120$ точек с гауссовским шумом. В первом случае использовался диапазон $x \in [-3, 3]$, во втором — $x \in [-2.5, 2.5]$. Эти параметры вместе с seed сохраняются в конфигурации

и в таблице `datasets.csv`, поэтому эксперимент воспроизводим.

Первый набор данных почти линейный:

$$y = 1.6x - 0.7 + 0.1 \sin(3x) + \varepsilon, \quad \text{Var}(\varepsilon) = 0.04.$$

Второй набор данных существенно нелинейный:

$$y = 0.35x^3 - 0.8x + \sin(2.8x) + 1.5 \exp\left(-\frac{1}{2} \left(\frac{x-1}{0.35}\right)^2\right) + \varepsilon,$$

где дисперсия шума равна 0.09.

Промежуточный вывод. Почти линейная зависимость нужна как контрольный пример: даже модель первой степени уже близка к данным. Нелинейный набор показывает, зачем увеличивать степень полинома и зачем нужна регуляризация, когда модель становится гибкой.

3 Методы оптимизации

3.1 Аналитическое решение

Для линейной модели без регуляризации используется решение через выборочные средние. Такой метод применим только к степени 1 и без L1/L2 членов.

Промежуточный вывод. Аналитическое решение почти бесплатно по числу итераций, но оно узкоспециализировано. Как только меняется степень модели или добавляется регуляризация, этот путь уже не подходит.

3.2 SGD и mini-batch GD

Стохастический градиентный спуск обновляет веса по одному объекту, а mini-batch GD использует подвыборку:

$$w_{t+1} = w_t - \alpha_t \nabla L_{B_t}(w_t).$$

В экспериментах использовалось убывание шага по правилу $\alpha_t = \alpha_0 / \sqrt{t+1}$, где $\alpha_0 = 0.03$. Максимальное число эпох равно 80, базовый mini-batch имеет

размер 16, а в отдельном исследовании сравнивались размеры 1, 4, 8, 16, 32, 64 и $m = 120$. В историях сохранялись полная функция потерь, эмпирический риск, L1/L2-слагаемые, размер batch, текущий шаг и счетчики вызовов.

Промежуточный вывод. Малый batch дает шумный, но частый сигнал о направлении. Большой batch ближе к полному градиенту, зато одно обновление становится менее локальным по данным. Поэтому сравнение batch size лучше смотреть не только по эпохам, но и по числу градиентных вычислений, а также по фиксированному бюджету вычислений.

3.3 Гаусс–Ньютон и Левенберг–Марквардт

Для суммы квадратов остатков можно использовать якобиан J :

$$(J^T J)p = -J^T r.$$

Метод Левенберга–Марквардта добавляет демпфирование:

$$(J^T J + \mu I)p = -J^T r.$$

Промежуточный вывод. Гаусс–Ньютон быстро работает, когда квадратичная аппроксимация остатков хороша. Демпфирование в Левенберге–Марквардте делает шаг осторожнее: при плохом локальном приближении метод ведет себя ближе к градиентному, а при хорошей модели — ближе к Гауссу–Ньютону.

4 Результаты

4.1 Сравнение методов

Таблица 1: Сводка по основным оптимизаторам без регуляризации

Метод	Успешных запусков	Лучшее f	Средн. итераций	N_f	N_g
AnalyticalLinearRegression1D	2	0.0394	1.00	1.00	1.00
GaussNewton	10	0.0385	1.00	2.00	2.00
LevenbergMarquardt	10	0.0385	3.20	4.20	4.20
MiniBatchGradientDescent	0	0.0618	80.00	81.00	1304.53
StochasticGradientDescent	0	0.0394	80.00	81.00	9681.00

Промежуточный вывод. В колонке успешных запусков считается только выполнение строгого критерия останова, а не просто получение хорошей аппроксимации. Поэтому SGD и mini-batch имеют ноль успешных запусков при лимите 80 эпох, хотя на части задач дают близкие значения функции потерь. Методы Гаусса–Ньютона и Левенберга–Марквардта быстрее приходят к малой ошибке, потому что используют якобиан всей модели.

4.2 Влияние степени полинома

Таблица 2: Лучшие значения функции потерь для Levenberg–Marquardt

Данные	degree 1	degree 2	degree 3	degree 4	degree 5
near_linear	0.03942	0.03936	0.03928	0.03861	0.03853
nonlinear	1.17604	1.15854	0.82320	0.80880	0.28341

Промежуточный вывод. Для почти линейных данных увеличение степени дает небольшой выигрыш: основная структура уже описана первой степенью. Для нелинейной зависимости степень 5 резко улучшает результат, потому что модель наконец получает достаточно гибкости для пика и осцилляции.

4.3 Регуляризация

Таблица 3: Регуляризация для nonlinear degree 5, Levenberg–Marquardt

Регуляризация	f	Итерации
нет	0.28341	4
L1, $\lambda = 0.001$	0.29050	4
L1, $\lambda = 0.01$	0.35078	5
L1, $\lambda = 0.1$	0.63649	53
L1, $\lambda = 1$	0.88710	58
L2, $\lambda = 0.001$	0.29969	4
L2, $\lambda = 0.01$	0.39649	4
L2, $\lambda = 0.1$	0.57235	3
L2, $\lambda = 1$	0.69107	3
Elastic Net, $\lambda = 0.001$	0.30646	4
Elastic Net, $\lambda = 0.01$	0.44208	4
Elastic Net, $\lambda = 0.1$	0.65768	47
Elastic Net, $\lambda = 1$	0.93095	85

Промежуточный вывод. Регуляризация увеличивает оптимизируемую функцию, потому что штраф входит прямо в значение f . Смысл штрафа — сдерживать коэффициенты и сделать модель менее резкой.

4.4 Сравнение Gauss–Newton и Levenberg–Marquardt

Для отдельного сравнения взята нелинейная задача степени 5 без регуляризации и один регуляризованный случай Elastic Net. Gauss–Newton делает недемпфированный шаг по аппроксимации $J^T J$, а Levenberg–Marquardt добавляет демпфирование и поэтому осторожнее реагирует на неудачную локальную модель.

Таблица 4: Сравнение Gauss–Newton и Levenberg–Marquardt

dataset	Reg	Method	L	Q	iter	N_f	N_g	status
nonlinear	Elastic Net l1=0.01, l2=0.01	GN	0.442082	0.338732	3	4	4	grad_tol
nonlinear	Elastic Net l1=0.01, l2=0.01	LM	0.442082	0.338732	4	5	5	grad_tol
nonlinear	none	GN	0.283406	0.283406	1	2	2	grad_tol
nonlinear	none	LM	0.283406	0.283406	4	5	5	grad_tol

Промежуточный вывод. Gauss–Newton может быть быстрее, когда квадратичная аппроксимация остатков уже достаточно точна. Levenberg–Marquardt устойчивее за счет демпфирования: при неудачном шаге параметр μ увеличивается, а при успешном уменьшается. На регуляризованных постановках это особенно важно, потому что штраф меняет форму локальной модели.

4.5 Исследование batch size

Таблица 5: Сравнение batch size для nonlinear degree 5

batch	L	Q	epochs	N_g	updates	$\Delta L/1000N_g$	status
1 (SGD)	0.491501	0.491501	80	9681	9600	0.0318115	max_epochs
4	0.542411	0.542411	80	2481	2400	0.0581244	max_epochs
8	0.561766	0.561766	80	1281	1200	0.112701	max_epochs
16	0.57688	0.57688	80	721	640	0.187528	max_epochs
32	0.595606	0.595606	80	401	320	0.353111	max_epochs
64	0.615706	0.615706	80	241	160	0.761656	max_epochs
120 (full)	0.641106	0.641106	80	161	80	3.1884	max_epochs

Промежуточный вывод. При убывающем шаге по числу обновлений SGD (batch 1) делает в 80 эпох 9600 обновлений и поэтому получает самый низкий итоговый $L(w)$ за фиксированное число эпох. Однако это достигается ценой огромного числа градиентных вычислений, поэтому SGD не является самым эффективным с точки зрения вычислительных затрат.

Если фиксировать бюджет градиентных вычислений (например, 1000 или 2000 пересчетов градиента), лучшими оказываются moderate batch (4–16): их градиентные оценки достаточно сглажены, чтобы двигаться стабильно, и при этом они успевают сделать больше обновлений, чем full batch. Слишком большие батчи (64, 120) дают наиболее стабильное направление, но за ограниченное число эпох делают мало обновлений и отстают по итоговому loss. Таким

образом, “лучший” batch зависит от критерия: при фиксированном числе эпох выигрывает SGD по точности, а при фиксированном бюджете вычислений — moderate batch (4–16).

5 Графики

5.1 Fit-графики базовых моделей




Рис. 1: Аппроксимация почти линейных данных моделью degree 1

Комментарий. Для линейной регрессии без регуляризации существует единственное решение метода наименьших квадратов. Поэтому линии analytic, SGD, GN и LM совпадают: все они сошлись к одному и тому же оптимуму (одинаковые $L = Q = 0.0394$). Различимость методов обеспечена разными маркерами. Mini-batch $b = 16$ за 80 эпох не дошёл до того же оптимума, поэтому его прямая чуть отличается и имеет больший loss.




Рис. 2: Аппроксимация почти линейных данных degree 1 по отдельным методам




Рис. 3: Аппроксимация почти линейных данных моделью degree 5

Комментарий. Данные почти линейны, поэтому модель пятой степени избыточно гибкая: все методы находят решение, близкое к прямой, старшие коэффициенты близки к нулю. Loss почти такой же, как у degree 1.




Рис. 4: Аппроксимация нелинейных данных моделью degree 1

Комментарий. Модель первой степени не способна описать нелинейную зависимость, поэтому все методы дают похожую прямую с высоким loss. Это пример недообучения: недостаточная сложность модели, а не неудача оптимизатора.




Рис. 5: Аппроксимация нелинейных данных моделью degree 5

Комментарий. GN и LM используют структуру суммы квадратов через якобиан остатков и быстро находят хорошее приближение ($L \approx 0.283$). SGD и mini-batch $b = 16$ за 80 эпох сошлись хуже: у них loss выше (0.49 и 0.58), а кривая менее похожа на истинную зависимость. Это следствие лимита в 80 эпох и убывающего шага.




Рис. 6: Аппроксимация nonlinear degree 5 по отдельным методам

Таблица 6: Каталог fit-графиков без регуляризации

dataset	degree	method	final L	status	plot
near_linear 1	analytic	0.0394248	converged	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_1_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 1	GN	0.0394248	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_1_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 1	LM	0.0394248	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_1_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 1	mini-batch	0.0617632	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_1_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 1	SGD	0.0394248	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_1_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 2	GN	0.0393645	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_2_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 2	LM	0.0393645	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_2_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 2	mini-batch	0.0776203	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_2_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 2	SGD	0.0394033	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_2_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 3	GN	0.0392792	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_3_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 3	LM	0.0392792	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_3_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 3	mini-batch	0.44255	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_3_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 3	SGD	0.0802666	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_3_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 4	GN	0.0386147	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_4_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 4	LM	0.0386147	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_4_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 4	mini-batch	0.431039	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_4_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 4	SGD	0.0806317	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_4_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 5	GN	0.0385289	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_5_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 5	LM	0.0385289	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_5_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 5	mini-batch	0.258229	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_5_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
near_linear 5	SGD	0.0632802	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_near_linear_degree_5_n_points_120_noise_variance_0.04_seed_11_x_range_-3.0_3.0_fit.png
nonlinear 1	analytic	1.17604	converged	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_1_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 1	GN	1.17604	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_1_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 1	LM	1.17604	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_1_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 1	mini-batch	1.17833	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_1_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 1	SGD	1.17604	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_1_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 2	GN	1.15854	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_2_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 2	LM	1.15854	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_2_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 2	mini-batch	1.16808	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_2_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 2	SGD	1.15858	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_2_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 3	GN	0.8232	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_3_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 3	LM	0.8232	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_3_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 3	mini-batch	0.863967	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_3_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 3	SGD	0.825881	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_3_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 4	GN	0.808797	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_4_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 4	LM	0.808797	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_4_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 4	mini-batch	0.845687	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_4_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 4	SGD	0.812977	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_4_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 5	GN	0.283406	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_5_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 5	LM	0.283406	grad_tol	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_5_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 5	mini-batch	0.57688	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_5_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 5	mini-batch	0.491501	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_5_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 5	mini-batch	0.542411	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_5_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 5	mini-batch	0.561766	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_5_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 5	mini-batch	0.57688	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_5_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 5	mini-batch	0.595606	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_5_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 5	mini-batch	0.615706	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_5_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 5	mini-batch	0.641106	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_5_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png
nonlinear 5	SGD	0.491501	max_epochs	./outputs/lab5/plots/PolynomialRegressionObjective_	dataset_kind_nonlinear_degree_5_n_points_120_noise_variance_0.09_seed_17_x_range_-2.5_2.5_fit.png

Комментарий к каталогу. Каждый fit-график содержит истинную зависимость, зашумленные точки и предсказания применимых методов для одной пары dataset-degree. Для аналитического решения строки есть только там, где оно применимо. Если метод технически неприменим к конкретной постановке, в полной таблице он отмечается статусом `not_applicable`.

5.2 Динамика loss




Рис. 7: История полного objective $L(w)$ для near_linear degree 5




Рис. 8: История $L(w)$ для near_linear degree 5 по отдельным методам




Рис. 9: История полного objective $L(w)$ для nonlinear degree 5




Рис. 10: История $L(w)$ для nonlinear degree 5 по отдельным методам

Комментарий к графикам. В легенде указаны итоговые $L(w)$, эмпирический риск $Q(w)$, число итераций/эпох и статус остановки. Для Gauss–Newton на этих задачах история состоит из одной–двух точек: метод сходится за один шаг (одно решение нормальной системы $J^T J \Delta w = -J^T r$), после чего выполняется критерий по норме градиента. Поэтому на history-графиках виден только маркер финального значения.




Рис. 11: Влияние размера batch по эпохам и trade-off между стоимостью, итоговым loss и шумом градиента




Рис. 12: Влияние размера batch по числу обновлений и по числу обработанных объектов




Рис. 13: Итоговая точность и удельное улучшение для разных batch size




Рис. 14: Loss при фиксированном бюджете градиентных вычислений и скорость достижения целевого loss

Комментарий к графикам. Ось `gradient_evaluations` сравнивает число обновлений/полных пересчетов градиента, но не полностью отражает стоимость batch разного размера: обновление на batch 1 дешевле, чем на batch 64.

Поэтому дополнительно показана ось processed samples. На trade-off графике ось x показывает размер batch как стоимость одного обновления, а ось y — теоретический проху шума mini-batch градиента $\frac{m-b}{b(m-1)}$. Графики fixed budget и target speed показывают, что при одном и том же бюджете градиентных вычислений moderate batch (4–16) обычно достигает меньшего loss быстрее, чем SGD или full batch.




Рис. 15: Полная функция потерь и эмпирический риск при разных регуляризациях

Комментарий к графикам. При росте регуляризации модель жертвует точностью на обучающей выборке ради более сдержанных коэффициентов. Полная функция потерь может расти из-за штрафа, даже если эмпирический риск меняется умеренно.




Рис. 16: L1- и L2-слагаемые при разных регуляризациях

Комментарий к графикам. Эти графики показывают, какая часть оптимизируемой функции связана именно со штрафом. При сильных коэффициентах регуляризации штраф начинает доминировать и подавляет гибкость

модели. Для вариантов без соответствующего штрафа слагаемое равно нулю, поэтому отдельные панельные графики для L1- и L2-слагаемых не приводятся.




Рис. 17: Аппроксимация nonlinear degree 5 до и после регуляризации




Рис. 18: Аппроксимация nonlinear degree 5 до и после регуляризации по отдельным вариантам

Комментарий к графику. Нерегуляризованная кривая сильнее подстраивается под обучающие точки, а регуляризованные варианты становятся более сглаженными. На этом графике виден практический смысл штрафа: он меняет форму модели, а не только значение целевой функции.




Рис. 19: Коэффициенты при регуляризации

Комментарий к графику. L1 сильнее зануляет или уменьшает отдельные коэффициенты, L2 сглаживает веса более равномерно, а Elastic Net сочетает оба эффекта. Слишком большая регуляризация ухудшает эмпирический риск, потому что модель становится недостаточно гибкой для нелинейной зависимости.




Рис. 20: Сравнение методов по итоговой функции потерь и среднему времени работы

Комментарий к графикам. Методы Гаусса–Ньютона и Левенберга–Марквардта выигрывают там, где структура суммы квадратов хорошо описывает задачу. Для `elapsed_seconds` используется логарифмическая

шкала, потому что времена методов отличаются на порядки. Время работы дополняет счетчики итераций и градиентов: метод с малым числом эпох не обязательно оказывается самым дешевым по фактическому времени.

6 Полная таблица экспериментов

Полная сводка 264 запусков хранится в `../outputs/lab5/tables/summary.csv`. Ниже приведена печатная версия таблицы, разбитая на масштабируемые блоки. Дополнительные CSV с историями, коэффициентами и данными сохранены в той же папке. Строки со статусом `skipped_batch_study` являются техническим фильтром для отдельного исследования batch size: они не означают неудачное обучение, а показывают, что соответствующая комбинация не входила в этот подэксперимент. Статусы `max_epochs` и `max_iter` означают, что строгий критерий остановки не был достигнут за лимит эпох или итераций, даже если итоговый loss уже стал приемлемым.

Таблица 7: Полная таблица экспериментов, блок 1

Data	Reg	Method	conv	f	Q	iter	N_f	N_g	time	Stop
near_linear, m=120, noise=0.04, d=1 none analytic {}			yes	0.0394248	0.0394248	1	1	1	1.740e-04	converged
near_linear, m=120, noise=0.04, d=1 none GN {}			yes	0.0394248	0.0394248	1	2	2	2.990e-04	grad_tol
near_linear, m=120, noise=0.04, d=1 none LM {}			yes	0.0394248	0.0394248	3	4	4	5.513e-04	grad_tol
near_linear, m=120, noise=0.04, d=1 none mini-batch batch_size=120			no	8.51481	8.51481	0	1	1	1.392e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=1 none mini-batch batch_size=16			no	8.51481	8.51481	0	1	1	1.347e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=1 none mini-batch batch_size=1			no	8.51481	8.51481	0	1	1	1.502e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=1 none mini-batch batch_size=32			no	8.51481	8.51481	0	1	1	2.123e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=1 none mini-batch batch_size=4			no	8.51481	8.51481	0	1	1	1.503e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=1 none mini-batch batch_size=64			no	8.51481	8.51481	0	1	1	1.510e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=1 none mini-batch batch_size=8			no	8.51481	8.51481	0	1	1	1.387e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=1 none mini-batch {}			no	0.0617632	0.0617632	80	81	721	0.0300554	max_epochs
near_linear, m=120, noise=0.04, d=1 none SGD {}			no	0.0394248	0.0394248	80	81	9681	0.29479	max_epochs
near_linear, m=120, noise=0.04, d=2 none analytic {}			no	8.51481	8.51481	0	1	1	8.760e-05	not_applicable
near_linear, m=120, noise=0.04, d=2 none GN {}			yes	0.0393645	0.0393645	1	2	2	2.058e-04	grad_tol
near_linear, m=120, noise=0.04, d=2 none LM {}			yes	0.0393645	0.0393645	3	4	4	4.619e-04	grad_tol
near_linear, m=120, noise=0.04, d=2 none mini-batch batch_size=120			no	8.51481	8.51481	0	1	1	1.109e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=2 none mini-batch batch_size=16			no	8.51481	8.51481	0	1	1	1.167e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=2 none mini-batch batch_size=1			no	8.51481	8.51481	0	1	1	1.200e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=2 none mini-batch batch_size=32			no	8.51481	8.51481	0	1	1	1.147e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=2 none mini-batch batch_size=4			no	8.51481	8.51481	0	1	1	1.150e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=2 none mini-batch batch_size=64			no	8.51481	8.51481	0	1	1	1.125e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=2 none mini-batch batch_size=8			no	8.51481	8.51481	0	1	1	1.235e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=2 none mini-batch {}			no	0.0776203	0.0776203	80	81	721	0.023609	max_epochs
near_linear, m=120, noise=0.04, d=2 none SGD {}			no	0.0394033	0.0394033	80	81	9681	0.30506	max_epochs
near_linear, m=120, noise=0.04, d=3 none analytic {}			no	8.51481	8.51481	0	1	1	9.600e-05	not_applicable
near_linear, m=120, noise=0.04, d=3 none GN {}			yes	0.0392792	0.0392792	1	2	2	2.585e-04	grad_tol
near_linear, m=120, noise=0.04, d=3 none LM {}			yes	0.0392792	0.0392792	3	4	4	5.352e-04	grad_tol
near_linear, m=120, noise=0.04, d=3 none mini-batch batch_size=120			no	8.51481	8.51481	0	1	1	1.269e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=3 none mini-batch batch_size=16			no	8.51481	8.51481	0	1	1	1.275e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=3 none mini-batch batch_size=1			no	8.51481	8.51481	0	1	1	1.547e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=3 none mini-batch batch_size=32			no	8.51481	8.51481	0	1	1	1.372e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=3 none mini-batch batch_size=4			no	8.51481	8.51481	0	1	1	1.318e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=3 none mini-batch batch_size=64			no	8.51481	8.51481	0	1	1	1.265e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=3 none mini-batch batch_size=8			no	8.51481	8.51481	0	1	1	1.258e-04	skipped_batch_study

Таблица 8: Полная таблица экспериментов, блок 2

Data	Reg	Method	conv	f	Q	iter	N_f	N_g	time	Stop
near_linear, m=120, noise=0.04, d=3 none mini-batch {}			no	0.44255	0.44255	80	81	721	0.0290545	max_epochs
near_linear, m=120, noise=0.04, d=3 none SGD {}			no	0.0802666	0.0802666	80	81	9681	0.309838	max_epochs
near_linear, m=120, noise=0.04, d=4 none analytic {}			no	8.51481	8.51481	0	1	1	8.830e-05	not_applicable
near_linear, m=120, noise=0.04, d=4 none GN {}			yes	0.0386147	0.0386147	1	2	2	2.609e-04	grad_tol
near_linear, m=120, noise=0.04, d=4 none LM {}			yes	0.0386147	0.0386147	3	4	4	6.022e-04	grad_tol
near_linear, m=120, noise=0.04, d=4 none mini-batch batch_size=120			no	8.51481	8.51481	0	1	1	1.415e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=4 none mini-batch batch_size=16			no	8.51481	8.51481	0	1	1	1.430e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=4 none mini-batch batch_size=1			no	8.51481	8.51481	0	1	1	1.505e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=4 none mini-batch batch_size=32			no	8.51481	8.51481	0	1	1	1.415e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=4 none mini-batch batch_size=4			no	8.51481	8.51481	0	1	1	1.506e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=4 none mini-batch batch_size=64			no	8.51481	8.51481	0	1	1	1.477e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=4 none mini-batch batch_size=8			no	8.51481	8.51481	0	1	1	1.434e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=4 none mini-batch {}			no	0.431039	0.431039	80	81	721	0.0306696	max_epochs
near_linear, m=120, noise=0.04, d=4 none SGD {}			no	0.0806317	0.0806317	80	81	9681	0.341127	max_epochs
near_linear, m=120, noise=0.04, d=5 none analytic {}			no	8.51481	8.51481	0	1	1	9.720e-05	not_applicable
near_linear, m=120, noise=0.04, d=5 none GN {}			yes	0.0385289	0.0385289	1	2	2	1.980e-04	grad_tol
near_linear, m=120, noise=0.04, d=5 none LM {}			yes	0.0385289	0.0385289	4	5	5	5.419e-04	grad_tol
near_linear, m=120, noise=0.04, d=5 none mini-batch batch_size=120			no	8.51481	8.51481	0	1	1	1.136e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=5 none mini-batch batch_size=16			no	8.51481	8.51481	0	1	1	1.086e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=5 none mini-batch batch_size=1			no	8.51481	8.51481	0	1	1	1.193e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=5 none mini-batch batch_size=32			no	8.51481	8.51481	0	1	1	1.077e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=5 none mini-batch batch_size=4			no	8.51481	8.51481	0	1	1	1.127e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=5 none mini-batch batch_size=64			no	8.51481	8.51481	0	1	1	1.066e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=5 none mini-batch batch_size=8			no	8.51481	8.51481	0	1	1	1.203e-04	skipped_batch_study
near_linear, m=120, noise=0.04, d=5 none mini-batch {}			no	0.258229	0.258229	80	81	721	0.0246939	max_epochs
near_linear, m=120, noise=0.04, d=5 none SGD {}			no	0.0632802	0.0632802	80	81	9681	0.302332	max_epochs
nonlinear, m=120, noise=0.09, d=1 none analytic {}			yes	1.17604	1.17604	1	1	1	9.310e-05	converged
nonlinear, m=120, noise=0.09, d=1 none GN {}			yes	1.17604	1.17604	1	2	2	2.533e-04	grad_tol
nonlinear, m=120, noise=0.09, d=1 none LM {}			yes	1.17604	1.17604	3	4	4	5.417e-04	grad_tol
nonlinear, m=120, noise=0.09, d=1 none mini-batch batch_size=120			no	1.9544	1.9544	0	1	1	1.303e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=1 none mini-batch batch_size=16			no	1.9544	1.9544	0	1	1	1.390e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=1 none mini-batch batch_size=1			no	1.9544	1.9544	0	1	1	1.465e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=1 none mini-batch batch_size=32			no	1.9544	1.9544	0	1	1	1.505e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=1 none mini-batch batch_size=4			no	1.9544	1.9544	0	1	1	1.389e-04	skipped_batch_study

Таблица 9: Полная таблица экспериментов, блок 3

Data	Reg	Method	conv	f	Q	iter	N_f	N_g	time	Stop
nonlinear, m=120, noise=0.09, d=1 none mini-batch batch_size=64			no	1.9544	1.9544	0	1	1	1.311e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=1 none mini-batch batch_size=8			no	1.9544	1.9544	0	1	1	1.339e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=1 none mini-batch {}			no	1.17833	1.17833	80	81	721	0.0287797	max_epochs
nonlinear, m=120, noise=0.09, d=1 none SGD {}			no	1.17604	1.17604	80	81	9681	0.316098	max_epochs
nonlinear, m=120, noise=0.09, d=2 none analytic {}			no	1.9544	1.9544	0	1	1	8.970e-05	not_applicable
nonlinear, m=120, noise=0.09, d=2 none GN {}			yes	1.15854	1.15854	1	2	2	2.890e-04	grad_tol
nonlinear, m=120, noise=0.09, d=2 none LM {}			yes	1.15854	1.15854	3	4	4	5.884e-04	grad_tol
nonlinear, m=120, noise=0.09, d=2 none mini-batch batch_size=120			no	1.9544	1.9544	0	1	1	1.932e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=2 none mini-batch batch_size=16			no	1.9544	1.9544	0	1	1	1.535e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=2 none mini-batch batch_size=1			no	1.9544	1.9544	0	1	1	1.637e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=2 none mini-batch batch_size=32			no	1.9544	1.9544	0	1	1	1.548e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=2 none mini-batch batch_size=4			no	1.9544	1.9544	0	1	1	1.521e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=2 none mini-batch batch_size=64			no	1.9544	1.9544	0	1	1	1.464e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=2 none mini-batch batch_size=8			no	1.9544	1.9544	0	1	1	1.478e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=2 none mini-batch {}			no	1.16808	1.16808	80	81	721	0.0315242	max_epochs
nonlinear, m=120, noise=0.09, d=2 none SGD {}			no	1.15858	1.15858	80	81	9681	0.336049	max_epochs
nonlinear, m=120, noise=0.09, d=3 none analytic {}			no	1.9544	1.9544	0	1	1	1.052e-04	not_applicable
nonlinear, m=120, noise=0.09, d=3 none GN {}			yes	0.8232	0.8232	1	2	2	2.161e-04	grad_tol
nonlinear, m=120, noise=0.09, d=3 none LM {}			yes	0.8232	0.8232	3	4	4	5.276e-04	grad_tol
nonlinear, m=120, noise=0.09, d=3 none mini-batch batch_size=120			no	1.9544	1.9544	0	1	1	1.220e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=3 none mini-batch batch_size=16			no	1.9544	1.9544	0	1	1	1.346e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=3 none mini-batch batch_size=1			no	1.9544	1.9544	0	1	1	1.574e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=3 none mini-batch batch_size=32			no	1.9544	1.9544	0	1	1	1.277e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=3 none mini-batch batch_size=4			no	1.9544	1.9544	0	1	1	1.332e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=3 none mini-batch batch_size=64			no	1.9544	1.9544	0	1	1	1.893e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=3 none mini-batch batch_size=8			no	1.9544	1.9544	0	1	1	1.316e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=3 none mini-batch {}			no	0.863967	0.863967	80	81	721	0.0297629	max_epochs
nonlinear, m=120, noise=0.09, d=3 none SGD {}			no	0.825881	0.825881	80	81	9681	0.317792	max_epochs
nonlinear, m=120, noise=0.09, d=4 none analytic {}			no	1.9544	1.9544	0	1	1	1.038e-04	not_applicable
nonlinear, m=120, noise=0.09, d=4 none GN {}			yes	0.808797	0.808797	1	2	2	2.568e-04	grad_tol
nonlinear, m=120, noise=0.09, d=4 none LM {}			yes	0.808797	0.808797	3	4	4	6.583e-04	grad_tol
nonlinear, m=120, noise=0.09, d=4 none mini-batch batch_size=120			no	1.9544	1.9544	0	1	1	1.448e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=4 none mini-batch batch_size=16			no	1.9544	1.9544	0	1	1	1.439e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=4 none mini-batch batch_size=1			no	1.9544	1.9544	0	1	1	1.494e-04	skipped_batch_study

Таблица 10: Полная таблица экспериментов, блок 4

Data	Reg	Method	conv	f	Q	iter	N_f	N_g	time	Stop
nonlinear, m=120, noise=0.09, d=4 none		mini-batch batch_size=32	no	1.9544	1.9544	0	1	1	1.400e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=4 none		mini-batch batch_size=4	no	1.9544	1.9544	0	1	1	1.360e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=4 none		mini-batch batch_size=64	no	1.9544	1.9544	0	1	1	1.406e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=4 none		mini-batch batch_size=8	no	1.9544	1.9544	0	1	1	1.375e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=4 none		mini-batch {}	no	0.845687	0.845687	80	81	721	0.0305866	max_epochs
nonlinear, m=120, noise=0.09, d=4 none		SGD {}	no	0.812977	0.812977	80	81	9681	0.347259	max_epochs
nonlinear, m=120, noise=0.09, d=5 none		analytic {}	no	1.9544	1.9544	0	1	1	1.002e-04	not_applicable
nonlinear, m=120, noise=0.09, d=5 none		GN {}	yes	0.283406	0.283406	1	2	2	4.289e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 none		LM {}	yes	0.283406	0.283406	4	5	5	7.177e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 none		mini-batch batch_size=120	no	0.641106	0.641106	80	81	161	0.0096174	max_epochs
nonlinear, m=120, noise=0.09, d=5 none		mini-batch batch_size=16	no	0.57688	0.57688	80	81	721	0.0261374	max_epochs
nonlinear, m=120, noise=0.09, d=5 none		mini-batch batch_size=1	no	0.491501	0.491501	80	81	9681	0.298752	max_epochs
nonlinear, m=120, noise=0.09, d=5 none		mini-batch batch_size=32	no	0.595606	0.595606	80	81	401	0.0169437	max_epochs
nonlinear, m=120, noise=0.09, d=5 none		mini-batch batch_size=4	no	0.542411	0.542411	80	81	2481	0.076624	max_epochs
nonlinear, m=120, noise=0.09, d=5 none		mini-batch batch_size=64	no	0.615706	0.615706	80	81	241	0.0112118	max_epochs
nonlinear, m=120, noise=0.09, d=5 none		mini-batch batch_size=8	no	0.561766	0.561766	80	81	1281	0.043413	max_epochs
nonlinear, m=120, noise=0.09, d=5 none		mini-batch {}	no	0.57688	0.57688	80	81	721	0.0257298	max_epochs
nonlinear, m=120, noise=0.09, d=5 none		SGD {}	no	0.491501	0.491501	80	81	9681	0.312919	max_epochs
nonlinear, m=120, noise=0.09, d=5 L2=0.001		analytic {}	no	1.9544	1.9544	0	1	1	9.530e-05	not_applicable
nonlinear, m=120, noise=0.09, d=5 L2=0.001		GN {}	yes	0.299688	0.284206	1	2	2	2.235e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 L2=0.001		LM {}	yes	0.299688	0.284206	4	5	5	6.310e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 L2=0.001		mini-batch batch_size=120	no	1.9544	1.9544	0	1	1	1.211e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.001		mini-batch batch_size=16	no	1.9544	1.9544	0	1	1	1.347e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.001		mini-batch batch_size=1	no	1.9544	1.9544	0	1	1	1.387e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.001		mini-batch batch_size=32	no	1.9544	1.9544	0	1	1	1.319e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.001		mini-batch batch_size=4	no	1.9544	1.9544	0	1	1	2.996e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.001		mini-batch batch_size=64	no	1.9544	1.9544	0	1	1	1.279e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.001		mini-batch batch_size=8	no	1.9544	1.9544	0	1	1	1.341e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.001		mini-batch {}	no	0.577152	0.576964	80	81	721	0.0287681	max_epochs
nonlinear, m=120, noise=0.09, d=5 L2=0.001		SGD {}	no	0.492936	0.492079	80	81	9681	0.318739	max_epochs
nonlinear, m=120, noise=0.09, d=5 L2=0.01		analytic {}	no	1.9544	1.9544	0	1	1	9.170e-05	not_applicable
nonlinear, m=120, noise=0.09, d=5 L2=0.01		GN {}	yes	0.396494	0.321576	1	2	2	2.745e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 L2=0.01		LM {}	yes	0.396494	0.321576	4	5	5	7.654e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 L2=0.01		mini-batch batch_size=120	no	1.9544	1.9544	0	1	1	1.479e-04	skipped_batch_study

Таблица 11: Полная таблица экспериментов, блок 5

Data	Reg	Method	conv	f	Q	iter	N_f	N_g	time	Stop
nonlinear, m=120, noise=0.09, d=5 L2=0.01		mini-batch batch_size=16	no	1.9544	1.9544	0	1	1	2.216e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.01		mini-batch batch_size=1	no	1.9544	1.9544	0	1	1	1.620e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.01		mini-batch batch_size=32	no	1.9544	1.9544	0	1	1	1.846e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.01		mini-batch batch_size=4	no	1.9544	1.9544	0	1	1	1.494e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.01		mini-batch batch_size=64	no	1.9544	1.9544	0	1	1	1.510e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.01		mini-batch batch_size=8	no	1.9544	1.9544	0	1	1	3.589e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.01		mini-batch {}	no	0.579565	0.577713	80	81	721	0.0309589	max_epochs
nonlinear, m=120, noise=0.09, d=5 L2=0.01		SGD {}	no	0.505039	0.497148	80	81	9681	0.348079	max_epochs
nonlinear, m=120, noise=0.09, d=5 L2=0.1		analytic {}	no	1.9544	1.9544	0	1	1	8.790e-05	not_applicable
nonlinear, m=120, noise=0.09, d=5 L2=0.1		GN {}	yes	0.572355	0.514194	1	2	2	2.028e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 L2=0.1		LM {}	yes	0.572355	0.514194	3	4	4	4.491e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 L2=0.1		mini-batch batch_size=120	no	1.9544	1.9544	0	1	1	1.109e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.1		mini-batch batch_size=16	no	1.9544	1.9544	0	1	1	1.138e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.1		mini-batch batch_size=1	no	1.9544	1.9544	0	1	1	1.303e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.1		mini-batch batch_size=32	no	1.9544	1.9544	0	1	1	1.133e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.1		mini-batch batch_size=4	no	1.9544	1.9544	0	1	1	1.158e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.1		mini-batch batch_size=64	no	1.9544	1.9544	0	1	1	1.116e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.1		mini-batch batch_size=8	no	1.9544	1.9544	0	1	1	1.288e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=0.1		mini-batch {}	no	0.600537	0.584935	80	81	721	0.0240067	max_epochs
nonlinear, m=120, noise=0.09, d=5 L2=0.1		SGD {}	no	0.575686	0.536668	80	81	9681	0.340966	max_epochs
nonlinear, m=120, noise=0.09, d=5 L2=1		analytic {}	no	1.9544	1.9544	0	1	1	8.100e-05	not_applicable
nonlinear, m=120, noise=0.09, d=5 L2=1		GN {}	yes	0.691066	0.627626	1	2	2	2.950e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 L2=1		LM {}	yes	0.691066	0.627626	3	4	4	5.403e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 L2=1		mini-batch batch_size=120	no	1.9544	1.9544	0	1	1	1.354e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=1		mini-batch batch_size=16	no	1.9544	1.9544	0	1	1	1.361e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=1		mini-batch batch_size=1	no	1.9544	1.9544	0	1	1	1.501e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=1		mini-batch batch_size=32	no	1.9544	1.9544	0	1	1	1.344e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=1		mini-batch batch_size=4	no	1.9544	1.9544	0	1	1	1.426e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=1		mini-batch batch_size=64	no	1.9544	1.9544	0	1	1	1.525e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=1		mini-batch batch_size=8	no	1.9544	1.9544	0	1	1	1.391e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L2=1		mini-batch {}	no	0.693151	0.630845	80	81	721	0.0301348	max_epochs
nonlinear, m=120, noise=0.09, d=5 L2=1		SGD {}	no	0.691093	0.627345	80	81	9681	0.312488	max_epochs
nonlinear, m=120, noise=0.09, d=5 L1=0.001		analytic {}	no	1.9544	1.9544	0	1	1	9.320e-05	not_applicable
nonlinear, m=120, noise=0.09, d=5 L1=0.001		GN {}	yes	0.290504	0.283446	3	4	4	5.453e-04	grad_tol

Таблица 12: Полная таблица экспериментов, блок 6

Data	Reg	Method	conv	f	Q	iter	N_f	N_g	time	Stop
nonlinear, m=120, noise=0.09, d=5 L1=0.001		LM {}	yes	0.290504	0.283446	4	5	5	5.921e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 L1=0.001		mini-batch batch_size=120	no	1.9544	1.9544	0	1	1	1.163e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.001		mini-batch batch_size=16	no	1.9544	1.9544	0	1	1	1.269e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.001		mini-batch batch_size=1	no	1.9544	1.9544	0	1	1	1.416e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.001		mini-batch batch_size=32	no	1.9544	1.9544	0	1	1	1.151e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.001		mini-batch batch_size=4	no	1.9544	1.9544	0	1	1	2.587e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.001		mini-batch batch_size=64	no	1.9544	1.9544	0	1	1	1.297e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.001		mini-batch batch_size=8	no	1.9544	1.9544	0	1	1	1.247e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.001		mini-batch {}	no	0.577912	0.577099	80	81	721	0.0263099	max_epochs
nonlinear, m=120, noise=0.09, d=5 L1=0.001		SGD {}	no	0.493914	0.492242	80	81	9681	0.308346	max_epochs
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		analytic {}	no	1.9544	1.9544	0	1	1	9.890e-05	not_applicable
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		GN {}	yes	0.306456	0.284558	3	4	4	7.603e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		LM {}	yes	0.306456	0.284558	4	5	5	7.978e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		mini-batch batch_size=120	no	1.9544	1.9544	0	1	1	1.464e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		mini-batch batch_size=16	no	1.9544	1.9544	0	1	1	1.423e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		mini-batch batch_size=1	no	1.9544	1.9544	0	1	1	1.709e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		mini-batch batch_size=32	no	1.9544	1.9544	0	1	1	1.411e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		mini-batch batch_size=4	no	1.9544	1.9544	0	1	1	1.494e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		mini-batch batch_size=64	no	1.9544	1.9544	0	1	1	1.627e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		mini-batch batch_size=8	no	1.9544	1.9544	0	1	1	1.620e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		mini-batch {}	no	0.578182	0.577183	80	81	721	0.0308229	max_epochs
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.001, l2=0.001		SGD {}	no	0.49533	0.492818	80	81	9681	0.346702	max_epochs
nonlinear, m=120, noise=0.09, d=5 L1=0.01		analytic {}	no	1.9544	1.9544	0	1	1	8.940e-05	not_applicable
nonlinear, m=120, noise=0.09, d=5 L1=0.01		GN {}	yes	0.350779	0.28741	3	4	4	6.625e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 L1=0.01		LM {}	yes	0.350779	0.28741	5	6	6	8.935e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 L1=0.01		mini-batch batch_size=120	no	1.9544	1.9544	0	1	1	1.568e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.01		mini-batch batch_size=16	no	1.9544	1.9544	0	1	1	1.577e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.01		mini-batch batch_size=1	no	1.9544	1.9544	0	1	1	2.145e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.01		mini-batch batch_size=32	no	1.9544	1.9544	0	1	1	1.563e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.01		mini-batch batch_size=4	no	1.9544	1.9544	0	1	1	1.681e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.01		mini-batch batch_size=64	no	1.9544	1.9544	0	1	1	1.738e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.01		mini-batch batch_size=8	no	1.9544	1.9544	0	1	1	1.747e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.01		mini-batch {}	no	0.586858	0.579105	80	81	721	0.0267799	max_epochs
nonlinear, m=120, noise=0.09, d=5 L1=0.01		SGD {}	no	0.514688	0.499148	80	81	9681	0.318866	max_epochs

Таблица 13: Полная таблица экспериментов, блок 7

Data	Reg	Method	conv	f	Q	iter	N_f	N_g	time	Stop
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		analytic {}	no	1.9544	1.9544	0	1	1	1.088e-04	not_applicable
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		GN {}	yes	0.442082	0.338732	3	4	4	6.525e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		LM {}	yes	0.442082	0.338732	4	5	5	6.884e-04	grad_tol
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		mini-batch batch_size=120	no	1.9544	1.9544	0	1	1	1.385e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		mini-batch batch_size=16	no	1.9544	1.9544	0	1	1	1.563e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		mini-batch batch_size=1	no	1.9544	1.9544	0	1	1	1.665e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		mini-batch batch_size=32	no	1.9544	1.9544	0	1	1	1.559e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		mini-batch batch_size=4	no	1.9544	1.9544	0	1	1	1.480e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		mini-batch batch_size=64	no	1.9544	1.9544	0	1	1	1.418e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		mini-batch batch_size=8	no	1.9544	1.9544	0	1	1	1.453e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		mini-batch {}	no	0.589349	0.579952	80	81	721	0.0301033	max_epochs
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.01, l2=0.01		SGD {}	no	0.526463	0.504627	80	81	9681	0.323397	max_epochs
nonlinear, m=120, noise=0.09, d=5 L1=0.1		analytic {}	no	1.9544	1.9544	0	1	1	9.890e-05	not_applicable
nonlinear, m=120, noise=0.09, d=5 L1=0.1		GN {}	no	0.842052	0.683797	120	121	121	0.0166597	max_iter
nonlinear, m=120, noise=0.09, d=5 L1=0.1		LM {}	yes	0.636489	0.552115	53	54	36	0.0070951	grad_tol
nonlinear, m=120, noise=0.09, d=5 L1=0.1		mini-batch batch_size=120	no	1.9544	1.9544	0	1	1	1.315e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.1		mini-batch batch_size=16	no	1.9544	1.9544	0	1	1	1.228e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.1		mini-batch batch_size=1	no	1.9544	1.9544	0	1	1	1.486e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.1		mini-batch batch_size=32	no	1.9544	1.9544	0	1	1	1.215e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.1		mini-batch batch_size=4	no	1.9544	1.9544	0	1	1	1.294e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.1		mini-batch batch_size=64	no	1.9544	1.9544	0	1	1	2.224e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.1		mini-batch batch_size=8	no	1.9544	1.9544	0	1	1	1.254e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=0.1		mini-batch {}	no	0.651017	0.604252	80	81	721	0.0276794	max_epochs
nonlinear, m=120, noise=0.09, d=5 L1=0.1		SGD {}	no	0.637273	0.560006	80	81	9681	0.295105	max_epochs
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		analytic {}	no	1.9544	1.9544	0	1	1	9.350e-05	not_applicable
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		GN {}	no	0.738568	0.630125	120	121	121	0.0152842	max_iter
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		LM {}	yes	0.657683	0.583856	47	48	32	0.0211954	grad_tol
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		mini-batch batch_size=120	no	1.9544	1.9544	0	1	1	1.461e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		mini-batch batch_size=16	no	1.9544	1.9544	0	1	1	1.341e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		mini-batch batch_size=1	no	1.9544	1.9544	0	1	1	1.410e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		mini-batch batch_size=32	no	1.9544	1.9544	0	1	1	1.270e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		mini-batch batch_size=4	no	1.9544	1.9544	0	1	1	1.269e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		mini-batch batch_size=64	no	1.9544	1.9544	0	1	1	1.250e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		mini-batch batch_size=8	no	1.9544	1.9544	0	1	1	2.334e-04	skipped_batch_study

Таблица 14: Полная таблица экспериментов, блок 8

Data	Reg	Method	conv	f	Q	iter	N_f	N_g	time	Stop
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		mini-batch {}	no	0.663046	0.611714	80	81	721	0.0298723	max_epochs
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=0.1, l2=0.1		SGD {}	no	0.65796	0.584979	80	81	9681	0.340897	max_epochs
nonlinear, m=120, noise=0.09, d=5 L1=1		analytic {}	no	1.95441	1.9544	0	1	1	9.740e-05	not_applicable
nonlinear, m=120, noise=0.09, d=5 L1=1		GN {}	no	92.4598	33.2502	120	121	121	0.0184173	max_iter
nonlinear, m=120, noise=0.09, d=5 L1=1		LM {}	yes	0.887104	0.673023	58	59	38	0.0080628	grad_tol
nonlinear, m=120, noise=0.09, d=5 L1=1		mini-batch batch_size=120	no	1.95441	1.9544	0	1	1	9.950e-05	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=1		mini-batch batch_size=16	no	1.95441	1.9544	0	1	1	1.693e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=1		mini-batch batch_size=1	no	1.95441	1.9544	0	1	1	1.277e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=1		mini-batch batch_size=32	no	1.95441	1.9544	0	1	1	1.301e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=1		mini-batch batch_size=4	no	1.95441	1.9544	0	1	1	1.059e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=1		mini-batch batch_size=64	no	1.95441	1.9544	0	1	1	1.106e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=1		mini-batch batch_size=8	no	1.95441	1.9544	0	1	1	1.052e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 L1=1		mini-batch {}	no	0.888921	0.676152	80	81	721	0.0242308	max_epochs
nonlinear, m=120, noise=0.09, d=5 L1=1		SGD {}	no	0.888097	0.672031	80	81	9681	0.312199	max_epochs
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		analytic {}	no	1.95441	1.9544	0	1	1	1.265e-04	not_applicable
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		GN {}	no	1.96299	0.956379	120	121	121	0.0196036	max_iter
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		LM {}	yes	0.930946	0.684203	85	86	56	0.0129941	grad_tol
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		mini-batch batch_size=120	no	1.95441	1.9544	0	1	1	1.528e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		mini-batch batch_size=16	no	1.95441	1.9544	0	1	1	1.663e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		mini-batch batch_size=1	no	1.95441	1.9544	0	1	1	1.884e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		mini-batch batch_size=32	no	1.95441	1.9544	0	1	1	1.501e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		mini-batch batch_size=4	no	1.95441	1.9544	0	1	1	1.651e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		mini-batch batch_size=64	no	1.95441	1.9544	0	1	1	1.527e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		mini-batch batch_size=8	no	1.95441	1.9544	0	1	1	1.577e-04	skipped_batch_study
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		mini-batch {}	no	0.933856	0.689141	80	81	721	0.0308804	max_epochs
nonlinear, m=120, noise=0.09, d=5 Elastic Net l1=1, l2=1		SGD {}	no	0.932535	0.684271	80	81	9681	0.348885	max_epochs

7 Общий вывод

В лабораторной работе регрессия рассматривалась именно как задача оптимизации. Для линейной модели без регуляризации аналитическое решение

оказалось самым дешевым, но оно применимо только в узком случае. Методы Гаусса–Ньютона и Левенберга–Марквардта лучше использовали структуру суммы квадратов и быстро сходились на большинстве полиномиальных моделей.

SGD и mini-batch GD не достигали строгого критерия за заданное число эпох, но показали важную практическую особенность: качество зависит от правила шага и размера батча. При фиксированном числе эпох SGD дает самый низкий loss, так как делает больше обновлений, однако с точки зрения вычислительной эффективности (фиксированный бюджет градиентных вычислений) лучшим оказывается moderate batch (4–16). На нелинейных данных увеличение степени полинома заметно улучшало аппроксимацию, а регуляризация управляла компромиссом между точностью на обучении и величиной коэффициентов.