

Отчет по лабораторной работе №5

Полиномиальная регрессия и методы оптимизации

Выполнили:

Новиков Алексей Георгиевич, группа М3233

Душкин Александр Алексеевич, группа М3233

Санкт-Петербург

2026

Содержание

1	Постановка задачи	2
2	Данные и модели	2
3	Методы оптимизации	3
3.1	Аналитическое решение	3
3.2	SGD и mini-batch GD	3
3.3	Гаусс–Ньютон и Левенберг–Марквардт	4
4	Результаты	4
4.1	Сравнение методов	4
4.2	Влияние степени полинома	5
4.3	Регуляризация	5
5	Графики	6
6	Полная таблица экспериментов	11
7	Общий вывод	19

1 Постановка задачи

Цель работы — рассмотреть задачу одномерной регрессии как задачу оптимизации и сравнить несколько способов минимизации функции потерь. В работе использовались полиномиальные модели степеней от 1 до 5, два искусственных набора данных, варианты без регуляризации, с L1, L2 и Elastic Net, а также несколько оптимизаторов: аналитическое решение для линейной модели, SGD, mini-batch GD, Гаусс–Ньютон и Левенберг–Марквардт.

Для модели степени d использовалась матрица признаков

$$X = [1, z, z^2, \dots, z^d],$$

где z — нормированное значение исходного признака. Базовая функция потерь:

$$L(w) = \frac{1}{m} \|Xw - y\|^2.$$

При регуляризации добавлялись члены

$$\lambda_1 \sum_{i=1}^d \sqrt{w_i^2 + \delta^2} \quad \text{и} \quad \lambda_2 \sum_{i=1}^d w_i^2.$$

Свободный коэффициент w_0 в этих экспериментах не регуляризовался: штраф применялся только к коэффициентам при степенях нормированного признака. Для L1 использовалась сглаженная аппроксимация модуля с малым δ , чтобы сохранять дифференцируемость функции потерь для градиентных и гаусс–ньютоновских методов.

Промежуточный вывод. Регрессия удобна тем, что одна и та же задача допускает разные методы. Для линейного случая есть аналитическая формула, для стохастических методов важны батчи и шаг, а методы Гаусса–Ньютона используют структуру суммы квадратов через якобиан остатков.

2 Данные и модели

Первый набор данных почти линейный:

$$y = 1.6x - 0.7 + 0.1 \sin(3x) + \varepsilon, \quad \text{Var}(\varepsilon) = 0.04.$$

Второй набор данных существенно нелинейный:

$$y = 0.35x^3 - 0.8x + \sin(2.8x) + 1.5 \exp\left(-\frac{1}{2} \left(\frac{x-1}{0.35}\right)^2\right) + \varepsilon,$$

где дисперсия шума равна 0.09.

Промежуточный вывод. Почти линейная зависимость нужна как контрольный пример: даже модель первой степени уже близка к данным. Нелинейный набор показывает, зачем увеличивать степень полинома и зачем нужна регуляризация, когда модель становится гибкой.

3 Методы оптимизации

3.1 Аналитическое решение

Для линейной модели без регуляризации используется решение через выборочные средние. Такой метод применим только к степени 1 и без L1/L2 членов.

Промежуточный вывод. Аналитическое решение почти бесплатно по числу итераций, но оно узкоспециализировано. Как только меняется степень модели или добавляется регуляризация, этот путь уже не подходит.

3.2 SGD и mini-batch GD

Стохастический градиентный спуск обновляет веса по одному объекту, а mini-batch GD использует подвыборку:

$$w_{t+1} = w_t - \alpha_t \nabla L_{B_t}(w_t).$$

В экспериментах использовалось убывание шага по правилу $\alpha_t = \alpha_0 / \sqrt{t+1}$.

Промежуточный вывод. Малый batch дает шумный, но частый сигнал о направлении. Большой batch ближе к полному градиенту, зато одно обновление становится менее локальным по данным. Поэтому сравнение batch size лучше смотреть не только по эпохам, но и по числу градиентных вычислений.

3.3 Гаусс–Ньютон и Левенберг–Марквардт

Для суммы квадратов остатков можно использовать якобиан J :

$$(J^T J)p = -J^T r.$$

Метод Левенберга–Марквардта добавляет демпфирование:

$$(J^T J + \mu I)p = -J^T r.$$

Промежуточный вывод. Гаусс–Ньютон быстро работает, когда квадратичная аппроксимация остатков хороша. Демпфирование в Левенберге–Марквардте делает шаг осторожнее: при плохом локальном приближении метод ведет себя ближе к градиентному, а при хорошей модели — ближе к Гауссу–Ньютону.

4 Результаты

4.1 Сравнение методов

Таблица 1: Сводка по основным оптимизаторам

Метод	Успешных запусков	Лучшее f	Средн. итераций	N_f	N_g
AnalyticalLinearRegression1D	2	0.0394	1.00	1.00	1.00
GaussNewton	18	0.0385	23.00	24.00	24.00
LevenbergMarquardt	22	0.0385	13.91	14.91	11.05
MiniBatchGradientDescent	0	0.0618	80.00	81.00	1063.07
StochasticGradientDescent	0	0.0394	80.00	81.00	9681.00

Промежуточный вывод. Методы Гаусса–Ньютона и Левенберга–Марквардта быстрее приходят к малой ошибке, потому что используют якобиан всей модели. SGD и mini-batch не достигали строгой точности за 80 эпох, но на части задач давали близкие значения функции потерь.

4.2 Влияние степени полинома

Таблица 2: Лучшие значения функции потерь для Levenberg–Marquardt

Данные	degree 1	degree 2	degree 3	degree 4	degree 5
near_linear	0.03942	0.03936	0.03928	0.03861	0.03853
nonlinear	1.17604	1.15854	0.82320	0.80880	0.28341

Промежуточный вывод. Для почти линейных данных увеличение степени дает небольшой выигрыш: основная структура уже описана первой степенью. Для нелинейной зависимости степень 5 резко улучшает результат, потому что модель наконец получает достаточно гибкости для пика и осцилляции.

4.3 Регуляризация

Таблица 3: Регуляризация для nonlinear degree 5, Levenberg–Marquardt

Регуляризация	f	Итерации
нет	0.28341	4
L1, $\lambda = 0.001$	0.29050	4
L1, $\lambda = 0.01$	0.35078	5
L1, $\lambda = 0.1$	0.63649	53
L1, $\lambda = 1$	0.88710	58
L2, $\lambda = 0.001$	0.29969	4
L2, $\lambda = 0.01$	0.39649	4
L2, $\lambda = 0.1$	0.57235	3
L2, $\lambda = 1$	0.69107	3
Elastic Net, $\lambda = 0.01$	0.44208	4
Elastic Net, $\lambda = 1$	0.93095	85

Промежуточный вывод. Регуляризация увеличивает оптимизируемую функцию, потому что штраф входит прямо в значение f . Это не ошибка: смысл штрафа — не уменьшить training loss любой ценой, а сдержать коэффициенты и сделать модель менее резкой.

5 Графики




Рис. 1: Аппроксимация почти линейных данных полиномом степени 5

Комментарий к графику. Истинная зависимость почти линейна, поэтому высокая степень нужна мало. Если кривая почти совпадает с низкостепенной моделью, это говорит, что дополнительные коэффициенты в основном подстраивают мелкие колебания и шум.




Рис. 2: Аппроксимация нелинейных данных полиномом степени 5

Комментарий к графику. Нелинейный набор содержит пик и осцилляцию. Полином высокой степени лучше повторяет форму данных, но именно здесь возрастает риск лишней гибкости и становится полезной регуляризация.




Рис. 3: История loss для nonlinear degree 5

Комментарий к графику. Методы на всей выборке обычно дают более гладкую кривую loss, потому что используют полный градиент или якобиан.

Стохастические методы движутся шумнее: каждый шаг видит только часть данных.




Рис. 4: Loss в зависимости от числа вычислений градиента

Комментарий к графику. Такая ось честнее показывает цену стохастических методов. SGD делает много дешевых обновлений, но по счетчику градиентов видно, что путь к малой ошибке может быть дорогим.




Рис. 5: Влияние размера batch по эпохам

Комментарий к графику. Малые батчи обновляют веса чаще и шумнее, крупные батчи ближе к полному градиенту. Поэтому график по эпохам показывает не только качество направления, но и то, сколько обновлений было сделано внутри эпохи.




Рис. 6: Эмпирический риск при разных регуляризациях

Комментарий к графику. При росте регуляризации модель жертвует точностью на обучающей выборке ради более сдержанных коэффициентов. Если риск растет слишком сильно, штраф уже подавляет полезную гибкость модели.




Рис. 7: Коэффициенты при регуляризации

Комментарий к графику. L1 стремится занулять менее важные коэффициенты, L2 уменьшает их более плавно, а Elastic Net сочетает оба эффекта. По столбцам коэффициентов видно, как штраф меняет саму модель, а не только итоговый loss.




Рис. 8: Сравнение методов по итоговой функции потерь

Комментарий к графику. Методы Гаусса–Ньютона и Левенберга–Марквардта выигрывают там, где структура суммы квадратов хорошо описывает задачу. Градиентные методы проще, но им нужны дополнительные эпохи и аккуратный шаг.




Рис. 9: Сравнение методов по среднему времени работы

Комментарий к графику. Время работы дополняет счетчики итераций и градиентов: аналитическое решение почти мгновенно, методы Гаусса–Ньютона тратят больше линейной алгебры на шаг, а стохастические методы делают много дешевых обновлений. Поэтому метод с малым числом эпох не обязательно оказывается самым дешевым по фактическому времени.

6 Полная таблица экспериментов

Полная сводка 264 запусков хранится в `../outputs/lab5/tables/summary.csv`. Ниже приведена печатная версия таблицы, разбитая на масштабируемые блоки. Дополнительные CSV с историями, коэффициентами и данными сохранены в той же папке.

Таблица 4: Full Lab 5 experiment table: rows 1–32 of 264

dataset	deg	optimizer	params	λ_1	λ_2	conv	f	iter	N_f	N_g
near_linear	1	AnalyticalLinearRegression1D	{}	–	–	yes	0.03942	1	1	1
near_linear	1	StochasticGradientDescent	{}	–	–	no	0.03942	80	81	9681
near_linear	1	MiniBatchGradientDescent	{}	–	–	no	0.06176	80	81	721
near_linear	1	MiniBatchGradientDescent	{'batch_size': 1}	–	–	no	8.515	0	1	1
near_linear	1	MiniBatchGradientDescent	{'batch_size': 4}	–	–	no	8.515	0	1	1
near_linear	1	MiniBatchGradientDescent	{'batch_size': 8}	–	–	no	8.515	0	1	1
near_linear	1	MiniBatchGradientDescent	{'batch_size': 16}	–	–	no	8.515	0	1	1
near_linear	1	MiniBatchGradientDescent	{'batch_size': 32}	–	–	no	8.515	0	1	1
near_linear	1	MiniBatchGradientDescent	{'batch_size': 64}	–	–	no	8.515	0	1	1
near_linear	1	MiniBatchGradientDescent	{'batch_size': 120}	–	–	no	8.515	0	1	1
near_linear	1	GaussNewton	{}	–	–	yes	0.03942	1	2	2
near_linear	1	LevenbergMarquardt	{}	–	–	yes	0.03942	3	4	4
near_linear	2	AnalyticalLinearRegression1D	{}	–	–	no	8.515	0	1	1
near_linear	2	StochasticGradientDescent	{}	–	–	no	0.0394	80	81	9681
near_linear	2	MiniBatchGradientDescent	{}	–	–	no	0.07762	80	81	721
near_linear	2	MiniBatchGradientDescent	{'batch_size': 1}	–	–	no	8.515	0	1	1
near_linear	2	MiniBatchGradientDescent	{'batch_size': 4}	–	–	no	8.515	0	1	1
near_linear	2	MiniBatchGradientDescent	{'batch_size': 8}	–	–	no	8.515	0	1	1
near_linear	2	MiniBatchGradientDescent	{'batch_size': 16}	–	–	no	8.515	0	1	1
near_linear	2	MiniBatchGradientDescent	{'batch_size': 32}	–	–	no	8.515	0	1	1
near_linear	2	MiniBatchGradientDescent	{'batch_size': 64}	–	–	no	8.515	0	1	1
near_linear	2	MiniBatchGradientDescent	{'batch_size': 120}	–	–	no	8.515	0	1	1
near_linear	2	GaussNewton	{}	–	–	yes	0.03936	1	2	2
near_linear	2	LevenbergMarquardt	{}	–	–	yes	0.03936	3	4	4
near_linear	3	AnalyticalLinearRegression1D	{}	–	–	no	8.515	0	1	1
near_linear	3	StochasticGradientDescent	{}	–	–	no	0.08027	80	81	9681
near_linear	3	MiniBatchGradientDescent	{}	–	–	no	0.4425	80	81	721
near_linear	3	MiniBatchGradientDescent	{'batch_size': 1}	–	–	no	8.515	0	1	1
near_linear	3	MiniBatchGradientDescent	{'batch_size': 4}	–	–	no	8.515	0	1	1
near_linear	3	MiniBatchGradientDescent	{'batch_size': 8}	–	–	no	8.515	0	1	1
near_linear	3	MiniBatchGradientDescent	{'batch_size': 16}	–	–	no	8.515	0	1	1
near_linear	3	MiniBatchGradientDescent	{'batch_size': 32}	–	–	no	8.515	0	1	1

Таблица 5: Full Lab 5 experiment table: rows 33–64 of 264

dataset	deg	optimizer	params	λ_1	λ_2	conv	f	iter	N_f	N_g
near_linear	3	MiniBatchGradientDescent	{'batch_size': 64}	–	–	no	8.515	0	1	1
near_linear	3	MiniBatchGradientDescent	{'batch_size': 120}	–	–	no	8.515	0	1	1
near_linear	3	GaussNewton	{}	–	–	yes	0.03928	1	2	2
near_linear	3	LevenbergMarquardt	{}	–	–	yes	0.03928	3	4	4
near_linear	4	AnalyticalLinearRegression1D	{}	–	–	no	8.515	0	1	1
near_linear	4	StochasticGradientDescent	{}	–	–	no	0.08063	80	81	9681
near_linear	4	MiniBatchGradientDescent	{}	–	–	no	0.431	80	81	721
near_linear	4	MiniBatchGradientDescent	{'batch_size': 1}	–	–	no	8.515	0	1	1
near_linear	4	MiniBatchGradientDescent	{'batch_size': 4}	–	–	no	8.515	0	1	1
near_linear	4	MiniBatchGradientDescent	{'batch_size': 8}	–	–	no	8.515	0	1	1
near_linear	4	MiniBatchGradientDescent	{'batch_size': 16}	–	–	no	8.515	0	1	1
near_linear	4	MiniBatchGradientDescent	{'batch_size': 32}	–	–	no	8.515	0	1	1
near_linear	4	MiniBatchGradientDescent	{'batch_size': 64}	–	–	no	8.515	0	1	1
near_linear	4	MiniBatchGradientDescent	{'batch_size': 120}	–	–	no	8.515	0	1	1
near_linear	4	GaussNewton	{}	–	–	yes	0.03861	1	2	2
near_linear	4	LevenbergMarquardt	{}	–	–	yes	0.03861	3	4	4
near_linear	5	AnalyticalLinearRegression1D	{}	–	–	no	8.515	0	1	1
near_linear	5	StochasticGradientDescent	{}	–	–	no	0.06328	80	81	9681
near_linear	5	MiniBatchGradientDescent	{}	–	–	no	0.2582	80	81	721
near_linear	5	MiniBatchGradientDescent	{'batch_size': 1}	–	–	no	8.515	0	1	1
near_linear	5	MiniBatchGradientDescent	{'batch_size': 4}	–	–	no	8.515	0	1	1
near_linear	5	MiniBatchGradientDescent	{'batch_size': 8}	–	–	no	8.515	0	1	1
near_linear	5	MiniBatchGradientDescent	{'batch_size': 16}	–	–	no	8.515	0	1	1
near_linear	5	MiniBatchGradientDescent	{'batch_size': 32}	–	–	no	8.515	0	1	1
near_linear	5	MiniBatchGradientDescent	{'batch_size': 64}	–	–	no	8.515	0	1	1
near_linear	5	MiniBatchGradientDescent	{'batch_size': 120}	–	–	no	8.515	0	1	1
near_linear	5	GaussNewton	{}	–	–	yes	0.03853	1	2	2
near_linear	5	LevenbergMarquardt	{}	–	–	yes	0.03853	4	5	5
nonlinear	1	AnalyticalLinearRegression1D	{}	–	–	yes	1.176	1	1	1
nonlinear	1	StochasticGradientDescent	{}	–	–	no	1.176	80	81	9681
nonlinear	1	MiniBatchGradientDescent	{}	–	–	no	1.178	80	81	721
nonlinear	1	MiniBatchGradientDescent	{'batch_size': 1}	–	–	no	1.954	0	1	1

Таблица 6: Full Lab 5 experiment table: rows 65–96 of 264

dataset	deg	optimizer	params	λ_1	λ_2	conv	f	iter	N_f	N_g
nonlinear	1	MiniBatchGradientDescent	{'batch_size': 4}	–	–	no	1.954	0	1	1
nonlinear	1	MiniBatchGradientDescent	{'batch_size': 8}	–	–	no	1.954	0	1	1
nonlinear	1	MiniBatchGradientDescent	{'batch_size': 16}	–	–	no	1.954	0	1	1
nonlinear	1	MiniBatchGradientDescent	{'batch_size': 32}	–	–	no	1.954	0	1	1
nonlinear	1	MiniBatchGradientDescent	{'batch_size': 64}	–	–	no	1.954	0	1	1
nonlinear	1	MiniBatchGradientDescent	{'batch_size': 120}	–	–	no	1.954	0	1	1
nonlinear	1	GaussNewton	{}	–	–	yes	1.176	1	2	2
nonlinear	1	LevenbergMarquardt	{}	–	–	yes	1.176	3	4	4
nonlinear	2	AnalyticalLinearRegression1D	{}	–	–	no	1.954	0	1	1
nonlinear	2	StochasticGradientDescent	{}	–	–	no	1.159	80	81	9681
nonlinear	2	MiniBatchGradientDescent	{}	–	–	no	1.168	80	81	721
nonlinear	2	MiniBatchGradientDescent	{'batch_size': 1}	–	–	no	1.954	0	1	1
nonlinear	2	MiniBatchGradientDescent	{'batch_size': 4}	–	–	no	1.954	0	1	1
nonlinear	2	MiniBatchGradientDescent	{'batch_size': 8}	–	–	no	1.954	0	1	1
nonlinear	2	MiniBatchGradientDescent	{'batch_size': 16}	–	–	no	1.954	0	1	1
nonlinear	2	MiniBatchGradientDescent	{'batch_size': 32}	–	–	no	1.954	0	1	1
nonlinear	2	MiniBatchGradientDescent	{'batch_size': 64}	–	–	no	1.954	0	1	1
nonlinear	2	MiniBatchGradientDescent	{'batch_size': 120}	–	–	no	1.954	0	1	1
nonlinear	2	GaussNewton	{}	–	–	yes	1.159	1	2	2
nonlinear	2	LevenbergMarquardt	{}	–	–	yes	1.159	3	4	4
nonlinear	3	AnalyticalLinearRegression1D	{}	–	–	no	1.954	0	1	1
nonlinear	3	StochasticGradientDescent	{}	–	–	no	0.8259	80	81	9681
nonlinear	3	MiniBatchGradientDescent	{}	–	–	no	0.864	80	81	721
nonlinear	3	MiniBatchGradientDescent	{'batch_size': 1}	–	–	no	1.954	0	1	1
nonlinear	3	MiniBatchGradientDescent	{'batch_size': 4}	–	–	no	1.954	0	1	1
nonlinear	3	MiniBatchGradientDescent	{'batch_size': 8}	–	–	no	1.954	0	1	1
nonlinear	3	MiniBatchGradientDescent	{'batch_size': 16}	–	–	no	1.954	0	1	1
nonlinear	3	MiniBatchGradientDescent	{'batch_size': 32}	–	–	no	1.954	0	1	1
nonlinear	3	MiniBatchGradientDescent	{'batch_size': 64}	–	–	no	1.954	0	1	1
nonlinear	3	MiniBatchGradientDescent	{'batch_size': 120}	–	–	no	1.954	0	1	1
nonlinear	3	GaussNewton	{}	–	–	yes	0.8232	1	2	2
nonlinear	3	LevenbergMarquardt	{}	–	–	yes	0.8232	3	4	4

Таблица 7: Full Lab 5 experiment table: rows 97–128 of 264

dataset	deg	optimizer	params	λ_1	λ_2	conv	f	iter	N_f	N_g
nonlinear	4	AnalyticalLinearRegression1D	{}	–	–	no	1.954	0	1	1
nonlinear	4	StochasticGradientDescent	{}	–	–	no	0.813	80	81	9681
nonlinear	4	MiniBatchGradientDescent	{}	–	–	no	0.8457	80	81	721
nonlinear	4	MiniBatchGradientDescent	{'batch_size': 1}	–	–	no	1.954	0	1	1
nonlinear	4	MiniBatchGradientDescent	{'batch_size': 4}	–	–	no	1.954	0	1	1
nonlinear	4	MiniBatchGradientDescent	{'batch_size': 8}	–	–	no	1.954	0	1	1
nonlinear	4	MiniBatchGradientDescent	{'batch_size': 16}	–	–	no	1.954	0	1	1
nonlinear	4	MiniBatchGradientDescent	{'batch_size': 32}	–	–	no	1.954	0	1	1
nonlinear	4	MiniBatchGradientDescent	{'batch_size': 64}	–	–	no	1.954	0	1	1
nonlinear	4	MiniBatchGradientDescent	{'batch_size': 120}	–	–	no	1.954	0	1	1
nonlinear	4	GaussNewton	{}	–	–	yes	0.8088	1	2	2
nonlinear	4	LevenbergMarquardt	{}	–	–	yes	0.8088	3	4	4
nonlinear	5	AnalyticalLinearRegression1D	{}	–	–	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	–	–	no	0.4915	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	–	–	no	0.5769	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	–	–	no	0.4915	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	–	–	no	0.5424	80	81	2481
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	–	–	no	0.5618	80	81	1281
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	–	–	no	0.5769	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	–	–	no	0.5956	80	81	401
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	–	–	no	0.6157	80	81	241
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	–	–	no	0.6411	80	81	161
nonlinear	5	GaussNewton	{}	–	–	yes	0.2834	1	2	2
nonlinear	5	LevenbergMarquardt	{}	–	–	yes	0.2834	4	5	5
nonlinear	5	AnalyticalLinearRegression1D	{}	0.001	–	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	0.001	–	no	0.4939	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	0.001	–	no	0.5779	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	0.001	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	0.001	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	0.001	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	0.001	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	0.001	–	no	1.954	0	1	1

Таблица 8: Full Lab 5 experiment table: rows 129–160 of 264

dataset	deg	optimizer	params	λ_1	λ_2	conv	f	iter	N_f	N_g
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	0.001	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	0.001	–	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	0.001	–	yes	0.2905	3	4	4
nonlinear	5	LevenbergMarquardt	{}	0.001	–	yes	0.2905	4	5	5
nonlinear	5	AnalyticalLinearRegression1D	{}	0.01	–	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	0.01	–	no	0.5147	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	0.01	–	no	0.5869	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	0.01	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	0.01	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	0.01	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	0.01	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	0.01	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	0.01	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	0.01	–	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	0.01	–	yes	0.3508	3	4	4
nonlinear	5	LevenbergMarquardt	{}	0.01	–	yes	0.3508	5	6	6
nonlinear	5	AnalyticalLinearRegression1D	{}	0.1	–	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	0.1	–	no	0.6373	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	0.1	–	no	0.651	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	0.1	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	0.1	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	0.1	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	0.1	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	0.1	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	0.1	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	0.1	–	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	0.1	–	no	0.8421	120	121	121
nonlinear	5	LevenbergMarquardt	{}	0.1	–	yes	0.6365	53	54	36
nonlinear	5	AnalyticalLinearRegression1D	{}	1	–	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	1	–	no	0.8881	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	1	–	no	0.8889	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	1	–	no	1.954	0	1	1

Таблица 9: Full Lab 5 experiment table: rows 161–192 of 264

dataset	deg	optimizer	params	λ_1	λ_2	conv	f	iter	N_f	N_g
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	1	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	1	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	1	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	1	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	1	–	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	1	–	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	1	–	no	92.46	120	121	121
nonlinear	5	LevenbergMarquardt	{}	1	–	yes	0.8871	58	59	38
nonlinear	5	AnalyticalLinearRegression1D	{}	–	0.001	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	–	0.001	no	0.4929	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	–	0.001	no	0.5772	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	–	0.001	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	–	0.001	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	–	0.001	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	–	0.001	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	–	0.001	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	–	0.001	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	–	0.001	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	–	0.001	yes	0.2997	1	2	2
nonlinear	5	LevenbergMarquardt	{}	–	0.001	yes	0.2997	4	5	5
nonlinear	5	AnalyticalLinearRegression1D	{}	–	0.01	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	–	0.01	no	0.505	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	–	0.01	no	0.5796	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	–	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	–	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	–	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	–	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	–	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	–	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	–	0.01	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	–	0.01	yes	0.3965	1	2	2
nonlinear	5	LevenbergMarquardt	{}	–	0.01	yes	0.3965	4	5	5

Таблица 10: Full Lab 5 experiment table: rows 193–224 of 264

dataset	deg	optimizer	params	λ_1	λ_2	conv	f	iter	N_f	N_g
nonlinear	5	AnalyticalLinearRegression1D	{}	–	0.1	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	–	0.1	no	0.5757	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	–	0.1	no	0.6005	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	–	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	–	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	–	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	–	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	–	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	–	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	–	0.1	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	–	0.1	yes	0.5724	1	2	2
nonlinear	5	LevenbergMarquardt	{}	–	0.1	yes	0.5724	3	4	4
nonlinear	5	AnalyticalLinearRegression1D	{}	–	1	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	–	1	no	0.6911	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	–	1	no	0.6932	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	–	1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	–	1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	–	1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	–	1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	–	1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	–	1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	–	1	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	–	1	yes	0.6911	1	2	2
nonlinear	5	LevenbergMarquardt	{}	–	1	yes	0.6911	3	4	4
nonlinear	5	AnalyticalLinearRegression1D	{}	0.001	0.001	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	0.001	0.001	no	0.4953	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	0.001	0.001	no	0.5782	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	0.001	0.001	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	0.001	0.001	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	0.001	0.001	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	0.001	0.001	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	0.001	0.001	no	1.954	0	1	1

Таблица 11: Full Lab 5 experiment table: rows 225–256 of 264

dataset	deg	optimizer	params	λ_1	λ_2	conv	f	iter	N_f	N_g
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	0.001	0.001	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	0.001	0.001	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	0.001	0.001	yes	0.3065	3	4	4
nonlinear	5	LevenbergMarquardt	{}	0.001	0.001	yes	0.3065	4	5	5
nonlinear	5	AnalyticalLinearRegression1D	{}	0.01	0.01	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	0.01	0.01	no	0.5265	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	0.01	0.01	no	0.5893	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	0.01	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	0.01	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	0.01	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	0.01	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	0.01	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	0.01	0.01	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	0.01	0.01	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	0.01	0.01	yes	0.4421	3	4	4
nonlinear	5	LevenbergMarquardt	{}	0.01	0.01	yes	0.4421	4	5	5
nonlinear	5	AnalyticalLinearRegression1D	{}	0.1	0.1	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	0.1	0.1	no	0.658	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	0.1	0.1	no	0.663	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	0.1	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	0.1	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	0.1	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	0.1	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	0.1	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	0.1	0.1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	0.1	0.1	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	0.1	0.1	no	0.7386	120	121	121
nonlinear	5	LevenbergMarquardt	{}	0.1	0.1	yes	0.6577	47	48	32
nonlinear	5	AnalyticalLinearRegression1D	{}	1	1	no	1.954	0	1	1
nonlinear	5	StochasticGradientDescent	{}	1	1	no	0.9325	80	81	9681
nonlinear	5	MiniBatchGradientDescent	{}	1	1	no	0.9339	80	81	721
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 1}	1	1	no	1.954	0	1	1

Таблица 12: Full Lab 5 experiment table: rows 257–264 of 264

dataset	deg	optimizer	params	λ_1	λ_2	conv	f	iter	N_f	N_g
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 4}	1	1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 8}	1	1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 16}	1	1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 32}	1	1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 64}	1	1	no	1.954	0	1	1
nonlinear	5	MiniBatchGradientDescent	{'batch_size': 120}	1	1	no	1.954	0	1	1
nonlinear	5	GaussNewton	{}	1	1	no	1.963	120	121	121
nonlinear	5	LevenbergMarquardt	{}	1	1	yes	0.9309	85	86	56

7 Общий вывод

В лабораторной работе регрессия рассматривалась именно как задача оптимизации. Для линейной модели без регуляризации аналитическое решение оказалось самым дешевым, но оно применимо только в узком случае. Методы Гаусса–Ньютона и Левенберга–Марквардта лучше использовали структу-

ру суммы квадратов и быстро сходились на большинстве полиномиальных моделей.

SGD и mini-batch GD не достигали строгого критерия за заданное число эпох, но показали важную практическую особенность: качество зависит от правила шага и размера батча. На нелинейных данных увеличение степени полинома заметно улучшало аппроксимацию, а регуляризация управляла компромиссом между точностью на обучении и величиной коэффициентов.