

Методы оптимизации: лабораторные работы 2 и 3

Классический градиентный спуск, линейный поиск и модификации градиентного спуска

Алексей Новиков Александр Душкин

Университет ИТМО · Курс «Методы оптимизации»

2026

Использованные материалы лекций:

- постановка задачи минимизации и критерии остановки;
- классический градиентный спуск;
- одномерный поиск, условия Армихо и Вольфе;
- оценки сходимости градиентных методов;
- Momentum, Nesterov, AdaGrad, RMSProp, AdaDelta, Adam.

Что сравниваем:

- ЛР2: как выбирать длину шага α_k ;
- ЛР3: как менять направление и масштаб шага;
- цена метода: итерации, вызовы f , вызовы ∇f ;
- поведение на квадратичных и многоэкстремальных функциях.

Общая постановка

Ищется минимум гладкой функции:

$$\min_{x \in \mathbb{R}^n} f(x), \quad \|\nabla f(x_k)\| \leq \varepsilon.$$

Базовая схема спуска

$$x_{k+1} = x_k + \alpha_k p_k, \quad p_k \approx -\nabla f(x_k).$$

- В ЛР2 направление фиксировано как антиградиент, исследуется выбор α_k .
- В ЛР3 направление и масштаб шага меняются за счёт памяти метода.
- Во всех экспериментах ЛР3 использовалась точность $\varepsilon = 10^{-8}$.

Квадратичные функции

$$f(x) = \frac{1}{2}x^T Ax, \quad \nabla f(x) = Ax.$$

- Хорошо обусловленная: близкая кривизна по координатам.
- Плохо обусловленная: узкая вытянутая долина.

Квадратичные функции показывают влияние обусловленности, сложные функции проверяют устойчивость траекторий и критериев остановки.

Сложные функции

- Rosenbrock: узкая изогнутая долина, минимум $(1, 1)$.
- Ackley: локальные колебания, глобальный минимум $(0, 0)$.
- Himmelblau: четыре глобальных минимума и области притяжения.

Методы

- ConstantStepGD: $\alpha_k = \alpha$.
- ArmijoBacktracking: дробление шага до достаточного убывания.
- StrongWolfe: достаточное убывание и контроль кривизны.
- SteepestDescent: одномерная минимизация вдоль антиградиента.


Условие Армихо

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T p_k.$$

Сильное условие Вольфе

$$|\nabla f(x_k + \alpha p_k)^T p_k| \leq c_2 |\nabla f(x_k)^T p_k|.$$



ЛР2: постоянный шаг



- Слишком маленький α даёт устойчивый, но медленный спуск.
- Слишком большой α приводит к колебаниям или расходимости.
- На плохо обусловленной функции допустимая область шагов уже.


Это соответствует лекционной картине: скорость градиентного спуска на квадратичных функциях зависит от спектра матрицы Гессе.

ЛР2: цена линейного поиска



- Линейный поиск уменьшает риск неудачного шага.
- Но Armijo и Wolfe платят дополнительными вычислениями функции и градиента.
- Поэтому сравнивать нужно не только число итераций, но и стоимость итерации.

ЛР2: траектории на сложной функции Ackley



- Глобальный минимум Ackley находится в $(0, 0)$.
- Поверхность содержит локальные колебания, поэтому форма траектории важна.
- Для линейного поиска важно учитывать число вызовов f и ∇f .

В ЛР2 сравниваются классические правила выбора длины шага при общем направлении антиградиента.

ЛР3: идея модификаций градиентного спуска

Общая форма

$$x_{k+1} = x_k - \alpha_k d_k,$$

где d_k строится не только по текущему градиенту, но и по внутреннему состоянию метода.

Инерционные методы

- Momentum;
- Nesterov.

Адаптивные методы

- AdaGrad;
- RMSProp;
- AdaDelta;
- Adam.

Из лекций: модификации можно понимать как фильтрацию направления и координатное масштабирование шага.

ЛР3: основные формулы методов

Momentum

$$v_{k+1} = \beta v_k + \nabla f(x_k), \quad x_{k+1} = x_k - \alpha v_{k+1}.$$

AdaGrad

$$s_{k+1} = s_k + g_k^2, \quad x_{k+1} = x_k - \alpha \frac{g_k}{\sqrt{s_{k+1}} + \delta}.$$

RMSProp

$$s_{k+1} = \rho s_k + (1 - \rho) g_k^2.$$



Adam

$$m_{k+1} = \beta_1 m_k + (1 - \beta_1) g_k,$$

$$v_{k+1} = \beta_2 v_k + (1 - \beta_2) g_k^2.$$



Все операции с квадратами и делением в адаптивных методах выполняются по координатам.

ЛР3: чувствительность к параметрам




- Momentum чувствителен к паре $\alpha \times \beta$.
- Для AdaGrad число итераций часто упирается в `max_iter`, поэтому информативнее смотреть $f(x_k)$ и $\|\nabla f(x_k)\|$.

ЛР3: сходимость на квадратичных функциях



- На хорошо обусловленной функции многие траектории похожи, поэтому важен график $f(x_k)$.
- На плохо обусловленной функции адаптивное масштабирование помогает сгладить различие кривизн.

ЛР3: Ackley и критерий останковки



- На Ackley локальные колебания могут останавливать метод вне глобального минимума.
- `converged = true` означает выполнение $\|\nabla f(x_k)\| \leq 10^{-8}$.
- Это не всегда означает попадание в глобальный минимум $(0, 0)$.

Поэтому для многоэкстремальных функций в отчёте сравниваются также $f(x_k)$ и конечная точка.

Сравнение ЛР2 и ЛР3

ЛР2: линейный поиск

- меняется длина шага α_k ;
- направление остаётся антиградиентным;
- сильная сторона: контролируемое убывание функции;
- цена: дополнительные вызовы f и ∇f .

ЛР3: модификации спуска

- меняются направление и масштаб шага;
- используется внутреннее состояние метода;
- сильная сторона: ускорение и адаптация;
- риск: чувствительность к гиперпараметрам.

Главная практическая идея

Линейный поиск делает шаг безопаснее, а модификации градиентного спуска делают направление и масштаб шага информативнее.

- Постоянный шаг требует аккуратного выбора: слишком малый шаг медленный, слишком большой может разрушить сходимость.
- Armijo, Strong Wolfe и наискорейший спуск уменьшают риск неудачного шага, но увеличивают стоимость итерации.
- Momentum и Nesterov ускоряют движение за счёт памяти первого порядка.
- RMSProp и Adam оказались более устойчивыми среди адаптивных методов на выбранных сетках параметров.
- AdaGrad и AdaDelta нужно оценивать по конечному $f(x_k)$ и $\|\nabla f(x_k)\|$, если все запуски достигли `max_iter`.
- На Ackley и Himmelblau критерий по градиенту нужно интерпретировать осторожно: стационарная точка не всегда равна нужному глобальному минимуму.

- Отчёт ЛР2: `lab2/Report_demo2.tex`, графики: `outputs/lab2/`.
- Отчёт ЛР3: `lab3/Report_demo3.tex`, графики: `outputs/lab3/`.
- Общие функции и визуализация: `optimlib/src/optimlib/`.
- Полные CSV-сводки: `outputs/lab2/summary.csv`, `outputs/lab3/summary.csv`.