

Методы оптимизации: лабораторные работы 4 и 5

Методы Ньютона, квазиньютоновские методы и data-driven задачи регрессии

Алексей Новиков Александр Душкин

Университет ИТМО · Курс «Методы оптимизации»

2026

Использованные материалы:

- условия ЛР4 и ЛР5;
- отчеты `Report_demo4.tex`, `Report_demo5.tex`;
- код `functions.py`, `run.py`, `config.yaml`;
- результаты из `outputs/lab4` и `outputs/lab5`;
- конспект последних тем: CG, Newton, BFGS, GN, LM, regression.

Фокус защиты:

- постановка задачи и критерии остановки;
- какие методы реализованы и зачем;
- что показывают графики и таблицы;
- почему часть запусков формально неуспешна;
- выводы по методам и применимости.

Критерий остановки

$$\|\nabla f(x_k)\| \leq 10^{-8}.$$

Метрики в ЛР4

- число итераций;
- число вызовов f ;
- число вызовов ∇f ;
- число вызовов $\nabla^2 f$;
- причина остановки.

Метрики в ЛР5

- loss и empirical risk;
- число эпох или итераций;
- число вычислений градиента;
- время работы;
- коэффициенты модели.

Успешный запуск означает выполнение строгого критерия остановки, а не просто хорошее значение функции.

ЛР4: постановка и экспериментальный протокол

Задачи из условия

- линейный CG на SPD-квадратиках;
- нелинейные CG: Fletcher–Reeves и Polak–Ribiere;
- NewtonCholesky и NewtonDirectionChoice;
- trust-region Powell Dog Leg;
- DFP, BFGS, L-BFGS;
- сравнение с SciPy Newton-CG.

Эксперимент

- $n \in \{2, 10, 50, 100\}$;
- $\kappa \in \{1, 10, 100, 1000\}$;
- по два seed для каждой пары (n, κ) ;
- 2D-траектории: quadratic, Rosenbrock, Himmelblau, Ackley;
- всего 552 запуска.

Квадратичная модель и обусловленность

$$f(x) = \frac{1}{2} \langle Hx, x \rangle + \langle c, x \rangle + b, \quad \nabla f(x) = Hx + c, \quad \nabla^2 f(x) = H.$$

Если $H \succ 0$

$$x^* = -H^{-1}c, \quad f(x) = f(x^*) + \frac{1}{2} \langle H(x - x^*), x - x^* \rangle.$$

Число обусловленности

$$\kappa(H) = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

Рост κ делает линии уровня вытянутыми. Методы без явной информации о кривизне начинают идти зигзагами или требуют больше линейных поисков.

Линейный CG для SPD-квадратики

$$f(x) = \frac{1}{2}x^T A x - b^T x, \quad A \succ 0.$$

$$p_0 = -g_0, \quad \alpha_k = \frac{g_k^T g_k}{p_k^T A p_k},$$

$$x_{k+1} = x_k + \alpha_k p_k, \quad p_{k+1} = -g_{k+1} + \beta_k p_k.$$

Гарантия “не более n шагов” относится к SPD-квадратике и точной арифметике. На нелинейных функциях это уже эвристика направления.

Нелинейные варианты

$$\beta_k^{FR} = \frac{g_{k+1}^T g_{k+1}}{g_k^T g_k},$$

$$\beta_k^{PR} = \frac{g_{k+1}^T (g_{k+1} - g_k)}{g_k^T g_k}.$$

$$\beta_k = \max(0, \beta_k^{PR}) \quad \text{в PR+}.$$

$$m_k(p) = f(x_k) + g_k^T p + \frac{1}{2} p^T H_k p.$$

Newton

$$H_k p_k = -g_k.$$

Если $H_k \succ 0$, то

$$g_k^T p_k = -g_k^T H_k^{-1} g_k < 0.$$

LM / сдвиг Гессiana

$$(H_k + \lambda_k I) p_k = -g_k.$$

Trust-region

$$\min_{\|p\| \leq \Delta_k} m_k(p).$$

$$\rho_k = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)}.$$

Powell Dog Leg использует ломаную: шаг Коши
→ ньютоновский шаг.

$$s_k = x_{k+1} - x_k, \quad y_k = g_{k+1} - g_k, \quad G_k \approx H_k^{-1}.$$

Текущее условие

$$G_{k+1}y_k = s_k, \quad y_k^T s_k > 0.$$

BFGS

$$G_{k+1} = (I - \rho s y^T) G_k (I - \rho y s^T) + \rho s s^T, \quad \rho = \frac{1}{y^T s}.$$

DFP

$$G_{k+1} = G_k + \frac{s s^T}{s^T y} - \frac{G_k y y^T G_k}{y^T G_k y}.$$

L-BFGS не хранит полную матрицу G_k , а использует последние m пар (s_i, y_i) , поэтому память $O(mn)$ вместо $O(n^2)$.

ЛР4: что реализовано в коде

Функции

- `GeneratedQuadratic`;
- `Quadratic2DVisualization`;
- `Lab4Rosenbrock`;
- `Lab4Himmelblau`;
- `Lab4Ackley`.

Особенности эксперимента



- `history` траекторий включает стартовую точку x_0 ;
- на `Ackley` и `Himmelblau` есть запуски около седловых областей;
- для `NewtonDirectionChoice` сохранялась диагностика выбора направления;
- для `L-BFGS` исследовались $m = 3, 5, 10$.

ЛР4: средние метрики на GeneratedQuadratic

Метод	Успешных	Итерации	N_f	N_g	N_H
NewtonCholesky	32	1.00	3.00	3.00	1.00
NewtonDirectionChoice	32	1.00	3.00	3.00	1.00
PowellDogLeg	32	4.94	5.94	5.94	4.94
QuadraticConjugateGradient	16	70.25	71.25	71.25	1.00
BFGS	17	31.09	240.12	65.06	0.00
DFP	16	27.97	200.28	58.31	0.00
LBFGS	40	68.99	261.59	140.66	0.00
ScipyNewtonCG	25	10.69	28.66	27.22	10.88
FletcherReeves	8	239.91	2997.56	498.41	0.00
PolakRibiere	8	148.78	1727.84	307.00	0.00



L-BFGS считается по трем значениям памяти m , поэтому успешных запусков может быть больше, чем число отдельных квадратичных задач.

ЛР4: влияние размерности и обусловленности





Число итераций. При росте n и κ методы без точного Гессиана сильнее накапливают цену. Ньютоновские методы почти не увеличивают число итераций, но их шаг дороже из-за линейной алгебры.

ЛР4: вычислительная цена



Вызовы производных. Квазиньютоновские и CG-методы не вызывают Гессиан, но могут тратить больше градиентов. Ньютоновские методы экономят итерации, но платят вычислением и факторизацией Гессиана.

ЛР4: сравнение методов и память L-BFGS




Итоговое сравнение. SciPy Newton-CG служит устойчивой библиотечной точкой сравнения. У L-BFGS параметр m задает объем сохраняемой кривизны: больше памяти не всегда означает заметно меньше итераций.

ЛР4: диагностика NewtonDirectionChoice

Функция	Запусков	newton	modified_newton	steepest_descent	max λ
GeneratedQuadratic	32	32	0	0	0
Lab4Ackley	3	9	2	0	19.6791
Lab4Himmelblau	3	11	3	0	42
Lab4Rosenbrock	3	62	0	0	0
Quadratic2DVisualization	5	5	0	0	0


- На SPD-квадратиках всегда достаточно обычного ньютоновского направления.
- На Ackley и Himmelblau появляются сдвиги $H + \lambda I$: локальная кривизна не всегда положительно определена.
- Переход к steepest descent не потребовался: сдвиг Гессiana оказался достаточным.

ЛР4: траектории на квадратичной функции




На квадратичной функции ньютоновское направление быстро попадает в минимум. CG- и квазиньютоновские методы постепенно восстанавливают геометрию задачи.

ЛР4: траектории на Rosenbrock




У Rosenbrock узкая изогнутая долина. Траектории могут делать дуги и корректировки; это нормальное поведение для методов, использующих локальную информацию о кривизне.

ЛР4: траектории на Himmelblau



Старт выбран около седловой области, но не ровно в седле. Методы могут уходить к разным областям притяжения, поэтому важно видеть стартовую точку и первые шаги.

ЛР4: траектории на Ackley



Ackley содержит локальные колебания. Траектория может визуально “крутиться”, если локальная модель несколько раз меняет направление; это не ошибка само по себе.

ЛР4: выводы для защиты

- На SPD-квадратиках методы Ньютона ожидаемо выигрывают по итерациям: точный Гессиан полностью задает форму функции.
- Powell Dog Leg делает больше шагов, зато контролирует доверие к локальной квадратичной модели.
- BFGS и L-BFGS являются компромиссом: вторые производные не нужны, но информация о кривизне накапливается постепенно.
- Нелинейные CG чувствительны к линейному поиску и потере сопряженности.
- Формально успешный запуск требует $\|\nabla f(x_k)\| \leq 10^{-8}$; остановка по `max_iter` или `step_tol` может дать хорошую точку, но не считается строгой сходимостью.

ЛР5: постановка и экспериментальный протокол

Задачи из условия

- сгенерировать near-linear и nonlinear данные;
- построить полиномиальные модели степеней 1–5;
- сравнить analytic solution, SGD, mini-batch, GN, LM;
- изучить batch size;
- сравнить L1, L2 и Elastic Net.

Эксперимент

- 120 точек в каждом датасете;
- шум: 0.04 для near-linear и 0.09 для nonlinear;
- $\lambda \in \{10^{-3}, 10^{-2}, 10^{-1}, 1\}$;
- batch size: 1, 4, 8, 16, 32, 64, 120;
- всего 264 запуска.

Regression как задача оптимизации

Data-driven постановка

$$\{(x_i, y_i)\}_{i=1}^N, \quad f(x, w) \approx y.$$

Empirical risk для регрессии

$$Q(w) = \frac{1}{N} \sum_{i=1}^N (f(x_i, w) - y_i)^2.$$

Полиномиальная модель

$$f(x, w) = \sum_{j=0}^d w_j z^j, \quad z = \frac{x - \bar{x}}{s_x}.$$

Нормировка x уменьшает плохую обусловленность степеней x^j .

Loss на одном объекте

$$\ell_i(w) = (f(x_i, w) - y_i)^2.$$

Средний риск

$$Q(w) = \frac{1}{N} \sum_i \ell_i(w).$$

В экспериментах свободный коэффициент w_0 не регуляризуется: он отвечает за вертикальный сдвиг, а не за сложность формы.

Регуляризованная цель

$$F(w) = Q(w) + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2.$$

$$|w_j| \approx \sqrt{w_j^2 + \delta^2}$$

для сглаженной L1.

1D linear regression

$$f(x) = wx + b.$$

$$w = \frac{\overline{xy} - \bar{x}\bar{y}}{\overline{x^2} - (\bar{x})^2}, \quad b = \bar{y} - w\bar{x}.$$

SGD / mini-batch

$$w_{t+1} = w_t - \alpha_t \nabla \ell_{i_t}(w_t),$$

$$w_{t+1} = w_t - \alpha_t \frac{1}{|B_t|} \sum_{i \in B_t} \nabla \ell_i(w_t).$$

Gauss–Newton и Levenberg–Marquardt

$$F(w) = \frac{1}{2} \|r(w)\|^2, \quad r_i(w) = f(x_i, w) - y_i.$$

$$\nabla F(w) = J(w)^T r(w),$$

$$\nabla^2 F(w) = J(w)^T J(w) + \sum_{i=1}^N r_i(w) \nabla^2 r_i(w).$$

Gauss–Newton

$$J_k^T J_k p_k = -J_k^T r_k.$$

Levenberg–Marquardt

$$(J_k^T J_k + \lambda_k I) p_k = -J_k^T r_k.$$

Если residual мал или модель почти линейна по параметрам, $J^T J$ хорошо приближает точный Гессиан.

ЛР5: что реализовано в коде

Данные и модель

- `near_linear_true`;
- `nonlinear_true`;
- генерация шума;
- нормировка признака;
- матрица дизайна для степени d ;
- `PolynomialRegressionObjective`.

Методы

- `AnalyticalLinearRegression1D`;
- `StochasticGradientDescent`;
- `MiniBatchGradientDescent`;
- `GaussNewton`;
- `LevenbergMarquardt`;
- сохранение `histories`, `coefficients`, `datasets`, `summary`.

ЛР5: сравнение основных методов

Метод	Успешных	Лучшее f	Средн. итераций	N_f	N_g
AnalyticalLinearRegression1D	2	0.0394	1.00	1.00	1.00
GaussNewton	10	0.0385	1.00	2.00	2.00
LevenbergMarquardt	10	0.0385	3.20	4.20	4.20
MiniBatchGradientDescent	0	0.0618	80.00	81.00	1304.53
StochasticGradientDescent	0	0.0394	80.00	81.00	9681.00


SGD и mini-batch дошли до лимита 80 эпох, поэтому не считаются успешными по строгому критерию, хотя SGD на части задач дает близкий loss.

ЛР5: влияние степени полинома

Данные	degree 1	degree 2	degree 3	degree 4	degree 5
near_linear	0.03942	0.03936	0.03928	0.03861	0.03853
nonlinear	1.17604	1.15854	0.82320	0.80880	0.28341


- Для near-linear данных высокая степень почти не нужна: первая степень уже описывает основную структуру.
- Для nonlinear данных степень 5 резко улучшает loss: модель получает достаточно гибкости для пика и осцилляции.
- Это одновременно увеличивает риск переобучения, поэтому дальше исследовалась регуляризация.

ЛР5: аппроксимация near-linear данных





Истинная зависимость почти линейна. Высокая степень в основном подстраивает малые колебания и шум, поэтому выигрыш по loss небольшой.

ЛР5: аппроксимация nonlinear данных





Нелинейная зависимость содержит пик и осцилляцию. Полином степени 5 заметно лучше описывает форму данных, чем степени 1–4.

ЛР5: истории loss



История обучения. Ось по итерациям показывает динамику метода, а ось по вызовам градиента честнее сравнивает вычислительную цену SGD и mini-batch с GN/LM.

ЛР5: batch size





Размер батча. Малый batch дает частые шумные обновления, большой batch ближе к полному градиенту. Сравнение по эпохам и по N_g разделяет устойчивость и фактическую цену.

ЛР5: регуляризация nonlinear degree 5

Регуляризация	f	Итерации
нет	0.28341	4
L1, $\lambda = 0.001$	0.29050	4
L1, $\lambda = 0.01$	0.35078	5
L1, $\lambda = 0.1$	0.63649	53
L1, $\lambda = 1$	0.88710	58
L2, $\lambda = 0.001$	0.29969	4
L2, $\lambda = 0.01$	0.39649	4
L2, $\lambda = 0.1$	0.57235	3
L2, $\lambda = 1$	0.69107	3
Elastic Net, $\lambda = 0.001$	0.30646	4
Elastic Net, $\lambda = 0.01$	0.44208	4
Elastic Net, $\lambda = 0.1$	0.65768	47
Elastic Net, $\lambda = 1$	0.93095	85



Полная оптимизируемая функция растет, потому что штраф входит прямо в f . Это не ошибка: регуляризация ограничивает коэффициенты и гибкость модели.

ЛР5: loss и empirical risk при регуляризации





Полная цель и риск. Полный loss включает штраф, empirical risk измеряет ошибку аппроксимации. При росте регуляризации модель жертвует точностью на train ради более сдержанных коэффициентов.

ЛР5: что делает регуляризация с моделью



Форма кривой и коэффициенты. L1 сильнее зануляет коэффициенты, L2 уменьшает их плавнее, Elastic Net совмещает оба эффекта. На графике видно, что штраф меняет саму модель, а не только значение функции.

ЛР5: сравнение методов по loss и времени



Методы оптимизации. GN и LM используют структуру суммы квадратов и быстро получают малую ошибку. SGD дешевле в одном обновлении, но требует много градиентных вычислений и не достиг строгого критерия за 80 эпох.

ЛР5: выводы для защиты

- Регрессия сведена к минимизации эмпирического риска: loss строится из ошибок предсказания на данных.
- Для одномерной линейной модели аналитическое решение самое дешевое, но применимо только в узком случае.
- Gauss–Newton и LM эффективны, потому что используют якобиан невязок всей least squares задачи.
- LM устойчивее GN за счет демпфирования: плохой шаг увеличивает λ , хороший шаг уменьшает.
- Регуляризация повышает полную цель, но уменьшает гибкость модели и ограничивает коэффициенты.
- Строки `skipped_batch_study` в CSV являются техническим фильтром, а не неудачным обучением.

ЛР4

- классическая безусловная оптимизация;
- квадратичные модели;
- Гессиан и его аппроксимации;
- глобализация через line search и trust-region.

Главная связь: в обеих лабораторных локальная квадратичная модель объясняет направление шага, но в ЛР5 эта модель появляется из невязок данных.

ЛР5

- data-driven постановка;
- loss строится по выборке;
- least squares дает структуру $J^T J$;
- GN и LM используют ту же идею квадратичной модели.

Короткий чеклист перед защитой

- Почему $H \succ 0$ гарантирует направление спуска для Ньютона?
- Чем line search отличается от trust-region?
- Почему CG имеет конечную сходимость только на SPD-квадратиках?
- Что означает условие $s_k^T y_k > 0$ в BFGS/DFP?
- Что такое successful run и почему SGD может иметь 0 успешных запусков?
- Чем loss отличается от empirical risk и от регуляризованной цели?
- Почему GN заменяет точный Гессиан на $J^T J$?
- Почему LM переходит между GN и градиентным спуском?
- Что меняют L1, L2 и Elastic Net в коэффициентах модели?

- ЛР4: `outputs/lab4/summary.csv`, `outputs/lab4/plots`.
- ЛР5: `outputs/lab5/tables/summary.csv`, `histories`, `coefficients`, `datasets`.
- Графики презентации сохранены в `presentation/assets/labs_4_5/`.
- Полные таблицы остаются в CSV; в слайды вынесены агрегаты и ключевые иллюстрации для защиты.

Главный итог

Методы второго порядка выигрывают, когда Гессиан или структура `least squares` доступны и надежны; квазиньютоновские и стохастические методы являются компромиссом по памяти, производным и стоимости одной итерации.